A Novel Approach for Enhancing Sentiment Classification of Persian Reviews Using Convolutional Neural Network and Majority Voting Classifier

Milad Vazan

تحول دیجیتال و سیستم های هوشمند
Digital Transformation and Intelligent Systems
۲۵ و ۲۶ آذرماه ۱۴۰۰

مجتمع آموزش عالی لارستان
Larestan Higher Education Complex

رویکردی جدید برای ارتقا طبقه‌بندی احساسات نقدهای فارسی با استفاده از شبکه عصبی کانولوشنی و طبقه‌بند رای اکثریت

میلاد وزان[۱]

[۱]دانشگاه تبریز، گروه علوم کامپیوتر، تبریز m.vazan97@ms.tabrizu.ac.ir

چکیده

با توجه به توسعه سریع برنامه‌های کاربردی مبتنی‌بر اینترنت همانند رسانه‌های اجتماعی، تجزیه و تحلیل احساسات به یکی از حوزه‌های تحقیقاتی پرکاربرد پردازش زبان طبیعی و یک ابزار مهم استخراج نظرات از متون تبدیل شده است. چراکه حجم بسیار بزرگی از نظرات و نقدها امروزه از طریق رسانه‌های اجتماعی ایجاد می‌شود و این نظرات از اهمیت زیادی برخوردار هستند. با این حال، تحلیل و خلاصه‌سازی دستی آن‌ها نیاز به صرف وقت و هزینه زیادی دارد. از این رو تحلیل احساسات پا به عرصه گذاشته تا با ایجاد یک سیستم خودکار به سازماندهی و تحلیل آن‌ها بپردازد. طی سال‌های اخیر استفاده از یادگیری عمیق در تحلیل احساسات نتایج قدرتمندی را از خود نشان داده است. با این حال، ایجاد یک مدل به تنهایی ممکن است بهترین پیش‌بینی‌ها را ارائه ندهد و دچار خطاهایی همانند بایاس و واریانس بالا شود. در راستای کاهش این خطاها و ارتقا کارآیی پیش‌بینی‌های مدل، ترکیب چندین مدل که به عنوان یادگیری گروهی شناخته می‌شود، ممکن است نتایج بهتری را ارائه دهد. از این رو، هدف اصلی این مقاله ایجاد یک مدل مبتنی‌بر یادگیری گروهی با استفاده از چندین شبکه عصبی کانولوشنی و طبقه‌بند رای اکثریت است تا به ارتقا تحلیل احساسات در نقدهای فارسی بپردازد. مدل پیشنهادی بروری دو مجموعه داده نقدهای محصولات الکترونیکی و فیلم‌های سینمایی توسط اعتبارسنجی ۵-بخشی و ۱۰-بخشی ارزیابی شد. نتایج بدست آمده حاکی از آن است که این رویکرد جدید سبب افزایش کارآیی مدل تحلیل احساسات در زبان فارسی می‌شود.

واژه‌های کلیدی

یادگیری عمیق، تحلیل احساسات، یادگیری گروهی، شبکه عصبی کانولوشنی، طبقه‌بند رای اکثریت

---

۱. مقدمه

رسانه‌های اجتماعی در اشکال گوناگون خود همانند انجمن‌ها، وبلاگ‌ها، میکروبلاگ‌ها، سایت‌های نظردهی و غیره روزانه منجر به تولید حجم وسیعی از داده‌ها می‌شوند. چنین داده‌هایی در قالب نظرات، نقدها، دیدگاه‌ها در مورد خدمات، شرکت‌ها، سازمان‌ها، رویدادها، افراد، مسائل و موضوعات می‌باشد. صنایع تجاری و سیاست‌مداران به‌شدت تحت تاثیر این احساسات ارائه شده در شبکه‌های اجتماعی هستند. در نتیجه، استخراج، خلاصه‌سازی و تجزیه و تحلیل این حجم وسیع از داده‌ها نیاز به یک سیستم خودکار دارد تا به تحلیل احساسات این داده‌ها بپردازد [۱]. از همین‌رو، زمینه تحقیقاتی جدیدی با عنوان تحلیل احساسات پا به عرصه گذاشت. تحلیل احساسات که در زیر مجموعه مسائل مرتبط با پردازش زبان طبیعی قرار می‌گیرد، زمینه مطالعاتی است که هدف اصلی آن شناسایی، استخراج و طبقه‌بندی احساسات، نظرات، نگرش‌ها، افکار، قضاوت‌ها، نقدها و دیدگاه‌ها نسبت به موجودیت‌ها، سازمان‌ها، رویدادها و غیره بدون تعامل انسانی در قالب دسته‌های مثبت، منفی و یا خنثی می‌باشد [۲][۳][۴][۵]. تحلیل احساسات در همه‌ی زمینه‌های ممکن گسترش یافته است، از بهداشت و درمان، مالی، محصولات مصرفی، خدمات، ارتباطات از راه دور و تجارت الکترونیکی گرفته تا رویدادهای اجتماعی، مبارزات سیاسی و انتخابات [۲]. همچنین، درک موثر تمایلات احساسی از طریق داده‌ها برای مشاغل بسیار قابل توجه است و می‌تواند بر تصمیمات

مشتری نیز اثرگذار باشد. به عنوان مثال، در یک فروشگاه برخط، نظرات و نقدهای متفاوت درباره یک محصول می‌تواند بازگوکننده‌ی میزان رضایت و کیفیت یک محصول بوده و برای سایر خریداران راهنمای خوبی باشد.

دو رویکرد متفاوتی که محققین برای طبقه‌بندی احساسات در یک متن استفاده می‌کنند، رویکردهای مبتنی‌بر واژگان و مبتنی‌بر یادگیری ماشین می‌باشد [۶][۷][۸][۹][۱۰]. رویکرد دیگری را هم می‌توان ترکیبی از این دو نظر گرفت. رویکرد مبتنی‌بر واژگان، متمرکز بر استخراج کلمات یا عباراتی است که می‌تواند فرآیند طبقه‌بندی را در جهت‌گیری معنایی خاصی هدایت کند. هر واژه دارای بار معنایی خاصی است که از طریق یک فرهنگ واژه از کلمات با بار احساسی مثبت و منفی که پیش‌تر امتیازبندی شده‌اند، استخراج می‌شود. با جمع امتیاز بار احساسی واژه‌ها یا شمارش تعداد واژه‌های با بار مثبت و منفی، قطبیت کلی جمله بدست می‌آید. رویکرد یادگیری ماشین را می‌توان در حالت‌های مختلفی برای مساله تحلیل احساسات آموزش داد و بکار برد. در حالت یادگیری بانظارت با یک مجموعه داده آموزشی که پیش‌تر برچسب خورده است مدل آموزش می‌بیند تا قادر به یادگیری شود و بتواند در مواجهه با داده‌های دیده نشده رفتاری مشابه با داده‌های آموزش دیده از خود نشان دهد. در مقابل، در یادگیری بدون‌نظارت داده‌ها برچسب‌گذاری نمی‌شوند و مدل در تلاش است تا نقاط داده‌ای مشابه را در یک دسته قرار دهد. هر چند رویکردهای یادگیری ماشین نتایج قابل قبولی را در تحلیل احساسات بدست آورده است، با این حال این روش‌های سنتی یادگیری ماشین در راستای حل مساله نیاز به مهندسی ویژگی‌ها به‌صورت دستی دارد که این استخراج ویژگی‌ها به‌صورت دستی فرآیندی پرهزینه و چالش‌برانگیر است. همچنین، یافتن احساسات در متون ایجاد شده توسط کاربران به‌دلیل پیچیدگی‌های موجود در ساختار زبان، استفاده از کنایه‌ها، احساسات ضمنی و غیره نیاز به درک عمیق دارد و روش‌های کارآمدی برای مقابله با آن مورد نیاز است. از همین‌رو، روش‌های یادگیری عمیق امروزه بیشتر مورد استفاده قرار می‌گیرند. چراکه مدل‌های یادگیری عمیق این توانایی را دارند که به‌صورت خودکار از طریق تعداد لایه‌های زیاد در ساختارشان این ویژگی‌ها را استخراج کنند.

در راستای تحلیل احساسات در نقدهای فارسی در این مقاله از مدل‌های یادگیری عمیق استفاده کرده‌ایم. از آن‌جایی که ایجاد یک مدل به تنهایی ممکن است بهترین پیش‌بینی‌ها را ارائه ندهد، در جهت ارتقا مدل از یادگیری گروهی استفاده شده است. از همین‌رو، هدف اصلی این مقاله، توسعه رویکردی جدید برای ارتقا طبقه‌بندی احساسات نقدهای فارسی با استفاده از شبکه عصبی کانولوشنی و طبقه‌بند رای اکثریت است. در ادامه پس از مروری بر پیشینه و کارهای مرتبط با مساله، جزئیات روش پیشنهادی و ارزیابی نتایج را شرح می‌دهیم.

۲. پیشینه

۱.۲. یادگیری عمیق

طی سال‌های اخیر، به‌طور گسترده‌ای توسط محققین اثبات شده است که مدل‌های بازنمایی مبتنی‌بر یادگیری عمیق در مساله‌های مرتبط با طبقه‌بندی احساسات کارآیی بهتری دارند [۳][۱۱]. اتخاذ رویکردهای یادگیری عمیق در تحلیل احساسات به دلیل توانایی بسیار بالای مدل‌های یادگیری عمیق در یادگیری ویژگی‌ها به‌صورت خودکار است که می‌تواند به دقت و عملکرد بهتری دست یابند. یادگیری عمیق که به عنوان شبکه‌های عمیق نیز شناخته می‌شود، زیرمجموعه‌ای از یادگیری ماشین است که از عملکرد نورون‌ها در مغز انسان الهام گرفته شده است. مدل‌های یادگیری عمیق از تجربه توانایی یادگیری بدست می‌آورند. تجربه در این‌جا داده‌هایی است که به شبکه تغذیه می‌شود. آن‌ها روندها یا الگوهای داده‌ها را می‌آموزند، به‌طوری که وقتی داده‌های جدید در همان حوزه از مساله را مشاهده می‌کنند، توانایی پیش‌بینی آن‌ها را دارند. هرچه میزان داده‌های موجود برای آموزش شبکه بیشتر باشد، تجربه بیشتری از طریق شبکه بدست می‌آید و در نتیجه دقت پیش‌بینی‌ها بیشتر خواهد بود. کوچک‌ترین واحدی که یک شبکه عصبی را تشکیل می‌دهد، یک نورون است که بیشتر محاسبات در آن انجام می‌شود. در ساختار یک شبکه عصبی هزاران و یا حتی میلیون‌ها نورون وجود دارد که هر یک از این نورون‌ها در درون خود ویژگی‌های متفاوتی را ذخیره می‌کنند. این ویژگی‌ها با هم ترکیب شده و موارد درست را پیش‌بینی کنند. یک شبکه عصبی عمیق، دارای یک لایه ورودی، چندین لایه پنهان و در نهایت یک لایه خروجی برای پیش‌بینی است. شبکه‌ی عصبی کانولوشنی نمونه‌ای از یک شبکه‌ی عمیق است که طی سال‌های اخیر محبوبیت گسترده‌ای در حوزه‌ی پردازش زبان طبیعی بدست آورده است. در ادامه به مروری به این نوع از شبکه‌های عمیق خواهیم داشت.

۱.۱.۲. شبکه عصبی کانولوشنی (CNN)

شبکه عصبی کانولوشنی یا به اختصار CNN نوع ویژه‌ای از شبکه‌های عصبی عمیق هستند که عملکرد بسیار خوبی را در بینایی رایانه بدست آورده است. با این حال، به دلیل ساختار قدرتمند این شبکه‌ها در یافتن الگوهای تکراری و استخراج ویژگی‌های محلی، آن‌ها همچنین می‌تواند در پردازش زبان طبیعی کارآیی خوبی از خود نشان دهند [۱۲][۱۳]. از این رو، در مسائلی همانند تحلیل احساسات به دلیل آن‌که احساسات در متون با عبارات‌های کلیدی و خاصی تعیین می‌شود و شناسایی ویژگی‌ها از اهمیت ویژه‌ای برخوردار است، CNN با توانایی بسیار بالا در استخراج ویژگی‌های محلی به خوبی در این مساله عمل می‌کند [۱۴].

شبکه‌های عصبی پیش‌خور هر نورون ورودی را به تمام نورون‌های لایه بعدی متصل می‌کنند که به این فرآیند اتصال کامل گفته می‌شود. با این حال، این روش مستلزم محاسبه اضافی وزن‌ها است به‌طوری که بر سرعت آموزش مدل تاثیر زیادی می‌گذارد. به جای اتخاذ ارتباط کامل، CNN از اتصال جزئی استفاده می‌کند، یعنی هر نورون فقط به ناحیه‌ای از لایه ورودی متصل است که به عنوان میدان پذیرای محلی[1] نورون پنهان شناخته می‌شود. بنابراین، یک CNN پارامترهای کم‌تری نسبت به شبکه‌های عصبی پیش‌خور دارد و در نتیجه سرعت آموزش سریع‌تری نیز دارد [۱۵]. معماری کلی یک شبکه CNN شامل لایه ورودی، خروجی و پنهان است. لایه‌های پنهان در CNN نیز از چندین لایه تشکیل شده‌اند: لایه‌های کانولوشن، ادغام و متصل کامل. در لایه‌های کانولوشن نقشه‌های ویژگی از داده‌های ورودی با استفاده از عملگر کانولوشن بدست می‌آید. از لایه ادغام استفاده می‌شود تا مهم‌ترین ویژگی‌ها استخراج شوند و در نهایت از لایه متصل کامل برای بدست آوردن خروجی نهایی استفاده می‌کند [۳][۴]. شکل ۱ معماری یک مدل CNN را برای تحلیل احساسات نشان می‌دهد.

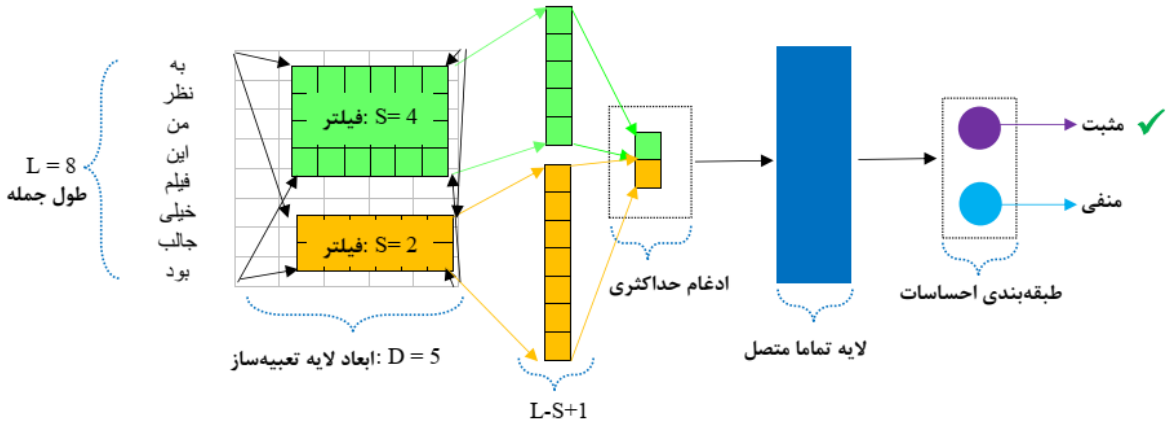

شکل ۱. معماری یک مدل CNN برای تحلیل احساسات [۱۴]

۲.۲. تعبیه‌سازی کلمات

الگوریتم‌های یادگیری عمیق قادر به درک داده‌های متنی به‌صورت خام نیستند، از این رو باید متن را به‌گونه‌ای تبدیل کرد تا شبکه قادر به درک و پردازش آن‌ها باشد. تعبیه‌سازی کلمات روشی برای بازنمایی کلمات است که هدف آن نمایش معنایی کلمات در قالب بردارهایی حقیقی است، جایی که کلمات با معنی و زمینه مشابه با بردارهای مشابه نشان داده می‌شوند [۳]. تعبیه‌سازی کلمات را برای متون می‌توان از دو رویکرد متفاوت بدست آورد. در رویکرد اول، در حین آموزش شبکه هم‌زمان با کار اصلی یاد گرفته می‌شوند. در این روش، در ابتدا مقادیر عددی برای بردارها به‌صورت تصادفی تولید می‌شود و سپس در حین آموزش این مقادیر از طریق بهینه‌سازی مانند دیگر لایه‌های شبکه بروزرسانی می‌شوند. رویکرد دوم، از طریق آموزش دادن با الگوریتم‌های خاصی همانند fasttext و glove برروی مجموعه داده‌های بزرگ متنی و استفاده از وزن‌های بدست آمده از این الگوریتم‌ها است.

[1] Local receptive field

۳.۲. یادگیری گروهی

یادگیری گروهی تکنیکی در یادگیری ماشین است که با ترکیب چندین مدل در یک مدل در تلاش است تا عملکرد مدل را در مقایسه با مدل‌های واحد افزایش دهد [۱۶][۱۷][۱۸]. اصل اساسی پشت مدل‌های گروهی این است که گروهی از یادگیرنده‌های ضعیف گرد هم آیند تا به کمک یک‌دیگر یک یادگیرنده قوی تشکیل دهند. شهود پشت مدل‌سازی گروهی مترادف با چیزی است که ما در زندگی روزمره به آن عادت کرده‌ایم، مانند درخواست نظر از چندین متخصص قبل از اتخاذ یک تصمیم خاص به‌منظور به‌حداقل رساندن احتمال تصمیم بد یا نتیجه نامطلوب [۱۹]. رویکردهای متفاوتی برای یادگیری گروهی در طول زمان تکامل یافته است تا منجر به تعمیم بهتر مدل‌های یادگیری شوند [۱۷]. این رویکردها را می‌توان در پنج دسته رای‌گیری[۲]، میانگین، دسته‌ای[۳]، تقویتی[۴] و چیدمان[۵] طبقه‌بندی کرد [۱۶]. از آن‌جایی که در این پژوهش از رویکرد رای‌گیری استفاده شده است، تنها به تشریح این رویکرد می‌پردازیم.

۱.۳.۲. طبقه‌بند رای‌گیر

طبقه‌بند رای‌گیر رویکردی از یادگیری گروهی است که با مجموعه‌ای از مدل‌های متعدد آموزش می‌بیند و خروجی کلاس را بر اساس بیشترین احتمال انتخاب کلاس پیش‌بینی می‌کند. هر یک از مدل‌ها یک نتیجه را برای یک نمونه داده ورودی پیش‌بینی می‌کند که به‌عنوان رای به نفع طبقه‌ای که مدل پیش‌بینی کرده است در نظر گرفته می‌شود [۱۹]. هنگامی که هر مدل نتیجه‌ای را پیش‌بینی می‌کند، پیش‌بینی نهایی بر اساس رای‌گیری برای یک کلاس خاص است. طبقه‌بند رای‌گیر از دو نوع رای‌گیری پشتیبانی می‌کند؛ رای‌گیری سخت و رای‌گیری نرم. در رای‌گیری سخت که به عنوان رای اکثریت شناخته می‌شود، کلاس خروجی پیش‌بینی شده، کلاسی با اکثریت آرا است؛ یعنی کلاسی که بیشترین احتمال پیش‌بینی توسط هر یک از طبقه‌بندها را داشته است. در رای‌گیری سخت در جهت جلوگیری از برابری آرا می‌توان تعداد طبقه‌بندها را عددی فرد در نظر گرفت. در صورتی که تعداد طبقه‌بندها عددی زوج باشد، باید از استراتژی خاصی استفاده کرد. در رای گیری نرم، کلاس خروجی پیش‌بینی‌ای است که بر اساس میانگین احتمال هر یک از طبقه‌بندها نسبت به آن کلاس ارائه می‌شود. به عنوان مثال، اگر مدل الف کلاس مثبت را با احتمال ۷۰ درصد و مدل ب آن را با احتمال ۹۰ درصد پیش‌بینی‌کند، رای‌گیری نرم محاسبه می‌کند که ۸۰ درصد احتمال مشاهدات متعلق به طبقه مثبت است، از این رو طبقه مثبت را انتخاب می‌کند.

۳. کارهای مرتبط

بصیری و همکاران [۲۰] واژه‌نامه‌ای برای زبان فارسی شامل ۱۵۰۰۰۰ جمله ارائه دادند که هر کدام از جمله‌ها با دو برچسب مرتبط است، یکی برچسب باینری که قطبیت جمله را نشان می‌دهد و دیگری رتبه پنج ستاره. نویسندگان از روش‌های رای‌گیری اکثریت و میانگین با استفاده از طبقه‌بند بیز ساده برای ارزیابی نتایج به ترتیب برای برچسب‌های قطبیت و پنج ستاره استفاده کردند. امیری و همکاران [۲۱] یک واژه‌نامه برای تشخیص قطبیت برای محصولات چند دامنه و نقدهای فیلم‌ها در زبان فارسی ایجاد کردند. پس از پیش پردازش داده‌ها از یک طبقه‌بند SVM برای ارزیابی عملکرد واژه‌نامه استفاده کردند و به دقت ۶۹ درصد رسیدند. دشتی‌پور و همکاران [۲۲] یک طبقه‌بند گروهی برای تحلیل احساسات در زبان فارسی با استفاده از الگوریتم‌های یادگیری ماشین و یادگیری عمیق ارائه دادند. نتایج تجربی آنان نشان داد که طبقه‌بند گروهی در مقایسه با طبقه‌بندهای یادگیری عمیق و طبقه‌بندهای سنتی کارآیی بهتری دارد. آن‌ها با استفاده از این طبقه‌بند گروهی به دقت ۷۹.۶۸ دست یافتند. روشنفکر و همکاران [۲۳] دو معماری شبکه عصبی عمیق CNN و Bi-LSTM را برای طبقه‌بندی احساسات در نقدهای محصولات الکترونیکی به زبان فارسی ارائه دادند. نتایج تجربی آن‌ها نشان داد که روش یادگیری عمیق عملکرد بهتری در امتیاز F در مقایسه با مدل Naive Bayes-SVM دارد. آن‌ها با استفاده از مدل CNN به امتیاز ۵۵.۴ درصد رسیدند. دشتی‌پور و همکاران [۲۴] دو معماری شبکه عصبی عمیق CNN و LSTM را برای طبقه‌بندی نقدهای فیلم‌های فارسی و هتل‌ها ارائه

---

[2] voting
[3] bagging
[4] boosting
[5] stacking

دادند و با رویکرد SVM مبتنی‌بر مهندسی ویژگی‌های دستی که قبلا پیشنهاد شده بود مقایسه کردند. نتایج آزمایش‌های آنان نشان داد که LSTM عملکرد بهتری در مقایسه با سایر روش‌ها دارد.

۴. روش پیشنهادی

۱.۴. پیش‌پردازش داده‌ها

به‌طور کلی مجموعه داده‌ها دارای نواقصی هستند که این امر سبب افزایش خطا در پیش‌بینی مدل‌ها و یا افزایش بار محاسباتی به دلیل وجود داده‌های بی‌فایده می‌شود. از این رو پیش‌پردازش داده‌ها امری ضروری قبل از آموزش مدل است. پیش‌پردازش‌هایی که در این مقاله صورت گرفته است شامل نرمال‌سازی متن، حذف کلمات توقف و حذف علائم نشانه‌گذار است. در نرمال‌سازی متن، تبدیل حروف عربی به فارسی (جایگزینی"ك " و "ي" با معادل فارسی خود یعنی"ک" و "ی") و همچنین حذف حروف تکراری همانند "عاااااالی" و "بددددد" صورت گرفت. در متون کلماتی وجود دارند (کلمات توقف) که کلمات کلیدی نیستند و حذف آن‌ها تاثیری در ارزش معنایی متن نخواهند داشت، همانند حروف اضافه، اسامی و اعداد، از این رو آن‌ها را نیز از حذف کرده‌ایم. همچنین، داده‌های خام شامل نمادها و نشانه‌هایی هستند که کاربردی در تحلیل متن ندارند و می‌توانند حذف شوند همانند: "." "،" "!" "؟"، از این رو اقدام به حذف آن‌ها نیز کرده‌ایم.

۲.۴. توکن‌سازی و آماده‌سازی داده‌ها برای لایه تعبیه‌ساز کلمات

پس از پیش‌پردازش برروی متون، توکن‌سازی متن به‌گونه‌ای که برای لایه تعبیه‌ساز کلمات مناسب باشد باید صورت پذیرد. از این رو، جملات تبدیل به کلمات می‌شوند و هر کلمه به عنوان یک توکن در نظر گرفته می‌شود. برای توکن‌سازی از کتابخانه Keras tokenizer استفاده شده است. از آن‌جایی لایه تعبیه‌ساز پردازش را با برداری به طول ثابت انجام می‌دهد، باید از روش دنباله‌گذاری[6] استفاده شود تا تمام جملات برداری یک اندازه داشته باشند. برای این منظور، یک عدد ثابت را برای طول جمله در نظر گرفته و بردار جمله‌ای با طول کم‌تر از این عدد را با صفر پر می‌کنیم تا به این عدد برسد. لایه تعبیه‌ساز سه پارامتر ورودی دارد که شامل اندازه ورودی که تعداد کلمات یکتا در مجموعه داده می‌باشد، اندازه بردار ثابت و طول بردار تعبیه‌ساز که بعد لایه تعبیه‌ساز می‌باشد. پس از دادن مقادیر این پارامترها به ورودی شبکه، لایه تعبیه‌ساز کلمات برای هر کلمه برداری با ابعاد داده شده ایجاد می‌کند و در ابتدا مقادیر این بردار را به‌صورت تصادفی اختصاص می‌دهد تا در طول فرآیند آموزش از طریق بهینه‌سازی وزن‌ها، اعداد مناسب برای آن‌ها پیدا شود.

۳.۴. معماری کلی روش پیشنهادی

روش پیشنهادی برای حل مساله تحلیل احساسات در نقدهای فارسی استفاده از تکنیک یادگیری گروهی مبتنی‌بر رویکرد رای‌گیری اکثریت است. ایده ترکیب طبقه‌بندهای مختلف از این اصل شروع می‌شود که هیچ الگوریتم یادگیری ماشین کاملی وجود ندارد. هر مدل محدودیت‌ها و ضعف‌های خود را دارد، بنابراین هدف این است که بهترین تصمیم ممکن را از طریق مجموعه‌ای از الگوریتم‌ها بدست آوریم و بر این محدودیت‌ها غلبه کنیم. ترکیب چندین الگوریتم حداقل دقیق‌تر از حدس تصادفی است، چراکه خطاهای تصادفی یکدیگر را خنثی می‌کنند و تصمیم صحیح تقویت می‌شود. در راستای این کار، ما از چهار مدل CNN با معماری یکسان استفاده کرده‌ایم. تنها تفاوت این چهار مدل CNN در ابعاد لایه تعبیه‌ساز کلمات است. به‌عبارت دیگر، هر یک از این مدل‌ها ویژگی‌های متنی متفاوتی را یاد می‌گیرند و در نهایت با ترکیب این ویژگی‌ها مدل نهایی با استفاده از طبقه‌بند رای اکثریت ساخته می‌شود تا از همه‌ی این ویژگی‌های یادگرفته شده توسط هر یک از مدل‌ها استفاده شود و میزان خطای کلی مدل کاهش پیدا کند و در نتیجه بهبود عملکرد مدل آموزشی را به‌همراه داشته باشد. شکل ۲ معماری کلی روش پیشنهادی را نشان می‌دهد. از آن‌جایی که در این معماری از ۴ طبقه‌بند استفاده شده است و تعداد طبقه‌بندها عددی زوج است که امکان برابری آرا از این منظر وجود دارد، در صورت برابری آرا، از این استراتژی استفاده می‌شود که رای دو مدل اول ملاک قرار گیرد.

---

[6] padding

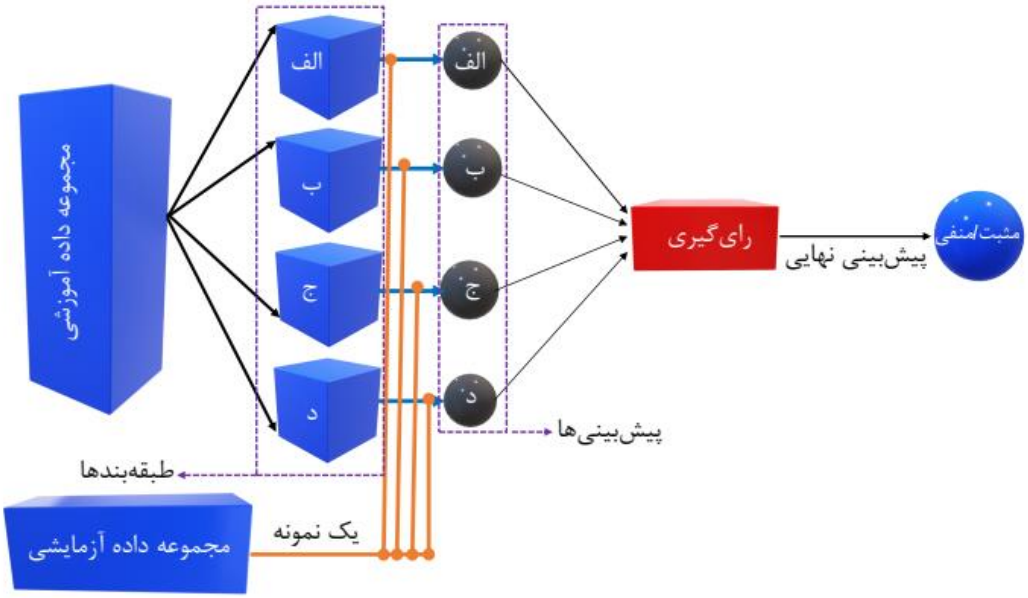

شکل ۲. معماری کلی روش پیشنهادی

۱.۳.۴. معماری مدل پایه

بعد از آن که داده‌ها بردارسازی شده و به طول ثابتی درآمدند تا برای پردازش توسط شبکه مناسب شدند، نوبت به تغذیه آن‌ها به شبکه است. تغذیه ورودی‌ها از طریق لایه ورودی (تعبیه‌ساز کلمات) صورت می‌گیرد. چهار مدل ایجاد شده برای استفاده در یادگیری گروهی در این پژوهش دارای معماری یکسانی هستند و تنها تفاوت بین این چهار مدل در همین ابعاد لایه تعبیه‌ساز است که از ابعاد مختلف ۱۰۰، ۱۵۰، ۲۰۰ و ۲۵۰ برای آموزش مدل استفاده شده است. معماری این مدل CNN در شکل ۲ قابل مشاهده است. در این معماری برای جلوگیری از بیش‌برازش از لایه حذف تصادفی با احتمال ۰.۵ بعد از لایه تعبیه‌ساز و قبل از لایه خروجی استفاده شده است. لایه کانولوشنی مورد استفاده دارای ۲۵۶ فیلتر با اندازه هسته ۳ است که به همراه ادغام حداکثری مورد استفاده قرار گرفته است تا به استخراج ویژگی‌های متنی بپردازد. در نهایت در لایه طبقه‌بندی از یک لایه متصل کامل با تابع فعال‌سازی سیگموید با ۱ استفاده شده است تا به طبقه‌بندی احساسات نقدها در قطبیت‌های مثبت یا منفی را انجام دهد.

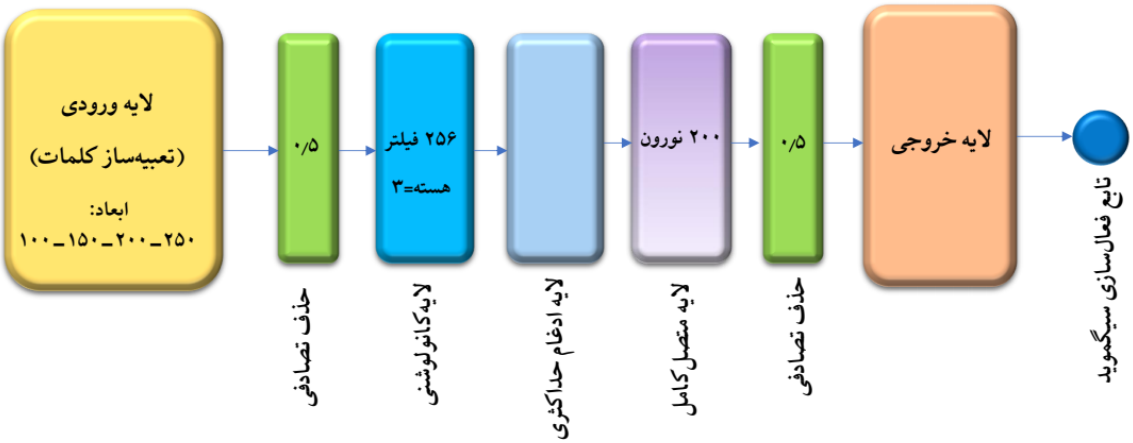

شکل ۳. معماری مدل CNN

۴.۴. آموزش شبکه

مرحله اصلی و مهم پس از طراحی مدل در یادگیری عمیق، آموزش شبکه است. در این مرحله است که شبکه با یافتن وزن‌ها از طریق الگوریتم بهینه‌سازی توانایی یادگیری بدست می‌آورد. انتخاب الگوریتم بهینه‌سازی، جلوگیری از بیش‌برازش، انتخاب تابع زیان و غیره از جمله مواردی که در آموزش یک شبکه باید لحاظ شوند. در این پژوهش برای بهینه‌سازی از الگوریتم آدام به دلیل همگرایی سریع‌تر استفاده شده است. تمامی شبکه‌ها در ۱۰ دوره با اندازه دسته‌های ۲۵۶ آموزش دیده‌اند. از آن‌جایی که مساله مورد پژوهش طبقه‌بندی دودویی است، از تابع زیان آنتروپی متقاطع دودویی استفاده شد که معادله ۱ نحوه محاسبه آن را نشان می‌دهد.

$$Binary\ Cross\ Entropy(y,\hat{y}) = -\frac{1}{n}\sum_{i=1}^{n}(y_i \log(\hat{y}) + (1-y_i)(1-\log(\hat{y}))) \quad (۱)$$

که در این معادله n تعداد نمونه‌های آموزشی، $\hat{y}$ مقدار پیش‌بینی شده و y مقدار خروجی واقعی است.

۵. نتایج

۱.۵. مجموعه داده

در این مقاله از دو مجموعه داده نقدهای فیلم‌های سینمایی ایرانی و نقدهای محصولات الکترونیکی استفاده شده است. مجموعه داده نقدهای فیلم‌های سینمایی حاوی ۲۴۰۰ نقد می‌باشد که از این تعداد ۱۲۰۰ نقد مثبت و ۱۲۰۰ نقد آن قطبیت منفی دارد. این مجموعه داده از تارنمای سینماتیکت[۷] ایجاد شده است. مجموعه داده نقدهای محصولات الکترونیکی حاوی ۲۰۰۰ نقد می‌باشد که از این تعداد ۱۰۰۰ نقد آن قطبیت مثبت و ۱۰۰۰ نقد دیگر قطبیت منفی دارند. این مجموعه از تارنمای دیجی‌کالا[۸] ایجاد شده است.

۲.۵. ارزیابی کارآیی

در حالی‌که آموزش مدل یک گام کلیدی است، نحوه تعمیم‌دهی مدل برروی داده‌های دیده نشده جنبه‌ای به همان اندازه مهم است که باید پس از طراحی هر مدل یادگیری ماشین در نظر گرفته شود. باید این اطمینان حاصل شود که آیا مدل واقعا کارا است و می‌توان به نتایج پیش‌بینی‌های آن اعتماد کرد یا خیر. در راستای این کار ارزیابی کارآیی مدل نیاز است و با معیارهای خاصی صورت می‌گیرد. در ادامه این معیارها را تشریح کرده و پس از آن تکنیک اعتبارسنجی متقابل چندبخشی را برای ارزیابی مدل شرح خواهیم داد.

۱.۲.۵. معیارهای ارزیابی

معیارهای معمول مورد استفاده برای مسائل طبقه‌بندی عبارتنداز: دقت[۹]، صحت[۱۰]، فراخوانی[۱۱] و امتیاز F1. برای اندازه‌گیری مقادیر این معیارهای ارزیابی از TP (مثبت درست)، TN (منفی درست)، FP (مثبت کاذب) و FN (منفی کاذب) استفاده می‌شود. پیش‌بینی زمانی TP است که مدل کلاس مثبت را به درستی پیش‌بینی کند، در حالی‌که TN نتیجه‌ای است که در آن مدل به درستی دسته منفی را پیش‌بینی می‌کند. از سوی دیگر، FP هنگامی است که مدل به اشتباه نمونه منفی را مثبت پیش‌بینی می‌کند و FN نمونه‌ای از کلاس مثبت است که به عنوان منفی پیش‌بینی شده است. دقت، نسبت تعداد پیش‌بینی‌های درست به تعداد کل نمونه‌های ورودی است. فراخوانی، به توانایی یک مدل در پیش‌بینی موارد مثبت از کل موارد مثبت درست اشاره می‌کند. در حالی‌که صحت، کسری از موارد مثبت درست را در بین نمونه‌هایی که به عنوان مثبت پیش‌بینی شده‌اند، اندازه‌گیری می‌کند. صحت و فراخوانی به تنهایی ممکن است برای ارزیابی مدل مناسب نباشد، بنابراین از امتیاز F1 استفاده می‌شود که هم صحت و هم فراخوانی را شامل می‌شود و نشان می‌دهد طبقه‌بند چقدر دقیق است. هرچه امتیاز F1 بیشتر باشد، کارآیی مدل ما بهتر است. معادلات ۲ تا ۵ نحوه محاسبه این معیارها را نشان می‌دهد.

---

[7] https://cinematicket.org
[8] https://www.digikala.com
[9] Accuracy
[10] Precision
[11] Recall

$$\text{دقت} = \frac{TP+TN}{TP+TN+FP+FN} \quad (۲)$$

$$\text{فراخوانی} = \frac{TP}{TP+FN} \quad (۳)$$

$$\text{صحت} = \frac{TP}{TP+FP} \quad (۴)$$

$$\text{امتیاز F1} = 2 \times \frac{\text{فراخوانی} \times \text{صحت}}{\text{فراخوانی} + \text{صحت}} \quad (۵)$$

۲.۲.۵. اعتبارسنجی متقابل چند-بخشی

یک الگوریتم طبقه‌بندی می‌تواند برروی یک مجموعه داده خاص با مجموعه‌ای منحصر به فرد از پارامترها آموزش داده شود که می‌تواند مرز تصمیم‌گیری را متناسب با داده‌ها ایجاد کند. نتیجه آن الگوریتم خاص نه‌تنها به پارامترهای ارائه شده برای آموزش مدل بستگی دارد، بلکه به نوع داده‌های آموزشی نیز بستگی دارد. اگر داده‌های آموزشی حاوی واریانس کم یا داده‌ها یکنواخت باشد، ممکن است مدل منجر به بیش‌برازش گردد و نتایج جانبدارانه‌ای را نسبت به داده‌های دیده نشده ایجاد کند. بنابراین، از رویکردهایی همانند اعتبارسنجی متقابل برای به‌حداقل رساندن بیش‌برازش استفاده می‌شود. اعتبارسنجی متقابل تکنیکی است که مجموعه آموزشی اصلی را به دو مجموعه داده آموزشی و آزمایشی (اعتبارسنجی) تقسیم می‌کند. رایج‌ترین روش اعتبارسنجی متقابل، اعتبارسنجی متقابل چند-بخشی است که مجموعه داده اصلی را به k بخش با اندازه یکسان تقسیم می‌کند. k یک عدد مشخص شده توسط کاربر است که معمولا ۵ یا ۱۰ انتخاب می‌شود. در این روش هر بار یکی از زیر مجموعه‌های k به‌عنوان مجموعه اعتبارسنجی (آزمون) مورد استفاده قرار می‌گیرد و k-1 زیر مجموعه‌ی دیگر برای تشکیل یک مجموعه آموزشی کنار هم قرار می‌گیرند. برای بدست آوردن کارآیی کل مدل، برآورد خطا در تمام آزمایش‌ها به‌طور میانگین محاسبه می‌شود.

در تکنیک اعتبارسنجی متقابل چند-بخشی هر یک از داده‌ها دقیقا یک بار در یک مجموعه آزمایشی قرار و یک بار در یک مجموعه آموزشی قرار می‌گیرد. این امر به‌طور قابل توجهی بایاس و واریانس را کاهش می‌دهد، چراکه تضمین می‌کند هر نمونه‌ای از مجموعه داده اصلی این شانس را دارد که در مجموعه آموزشی و آزمایشی ظاهر شود. اگر داده های ورودی محدودی داشته باشیم، اعتبارسنجی متقابل چند-بخشی از بهترین روش‌ها برای ارزیابی کارآیی یک مدل است.

۲.۵. نتایج آزمایش‌ها برروی دو مجموعه داده

تمامی آزمایش‌های این مقاله در محیط Google Colab با فعال بودن GPU انجام شده است. برای ساخت و آموزش مدل پیشنهادی برروی هر دو مجموعه داده دیجی کالا و سینماتیکت از کتابخانه Keras در بستر TensorFlow استفاده شده است. نتایج تمامی آزمایش‌ها با استفاده از اعتبار سنجی ۵-بخشی و ۱۰-بخشی بر اساس معیارهای دقت، فراخوانی، صحت و امتیاز F1 در جدول‌های ۱ تا ۲ آمده است. همان‌طور که مشاهده می‌شود، مدل پیشنهادی در مقایسه با مدل‌هایی که به‌صورت واحد آموزش دیده‌اند نتایج بهتری را در معیارهای دقت، فراخوانی و امتیاز F1 در هر دو مجموعه با هر دو ارزیابی اعتبارسنجی ۵-بخشی و ۱۰-بخشی بدست آورده‌اند. در مجموعه داده دیجی‌کالا، مدل پیشنهادی در معیار دقت و امتیاز F1 توانسته است به ترتیب به درصدهای ۹۱.۸ و ۹۱.۷۴ با اعتبارسنجی ۵-بخشی و درصدهای ۹۱.۵ و ۹۱.۵۶ با اعتبارسنجی ۱۰-بخشی برسد. همچنین، در مجموعه داده سینماتیکت، مدل پیشنهادی در معیار دقت و امتیاز F1 توانسته است به ترتیب به درصدهای ۹۳.۲۵ و ۹۳.۳۴ با اعتبارسنجی ۵-بخشی و درصدهای ۹۳.۶۷ و ۹۳.۷۲ با اعتبارسنجی ۱۰-بخشی برسد.

نمودارهای ترسیم‌شده در شکل‌های ۴ تا ۷ جزئیات بیشتری از هر اجرا با استفاده از اعتبارسنجی ۵-بخشی و ۱۰-بخشی را برای هر مجموعه داده نشان می‌دهند. در تمامی این نمودارهای ترسیمی منظور از مقدار عددی در D(.) نشان‌دهنده ابعاد لایه تعبیه‌ساز است. در جدول ۳ نیز روش پیشنهادی با کارهای گذشته (با مجموعه داده‌های متفاوت و تعداد داده‌های متفاوت) مورد مقایسه قرار گرفته است. همان‌طور که مشاهده می‌شود، روش پیشنهادی در همه‌ی معیارهای معمول طبقه‌بندی یعنی دقت، صحت، فراخوانی و امتیاز F1 نتایج بهتری داشته است.

جدول ۱. نتایج آزمایش‌ها برروی مجموعه داده دیجی‌کالا (نقدهای محصولات الکترونیکی)

مدل/ معیار		دقت		فراخوانی		صحت		امتیاز F1	
	ابعاد تعبیه‌ساز کلمات	۵-بخشی	۱۰-بخشی	۵-بخشی	۱۰-بخشی	۵-بخشی	۱۰-بخشی	۵-بخشی	۱۰-بخشی
CNN	۱۰۰	۹۱.۳۵	۸۹.۹	۹۱.۱۰	۸۷.۰۷	۹۱.۴۸	**۹۳.۷۸**	۹۱.۲۷	۹۰.۲۱
	۱۵۰	۸۹.۹	۹۰.۸	۸۸.۸۸	۸۹.۹۴	۹۱.۱۶	۹۲.۲۶	۸۹.۹۱	۹۰.۹۸
	۲۰۰	۹۰.۷۵	۹۱.۲۵	۸۸.۸۸	۹۰.۶۲	۹۳.۱۲	۹۲.۱۳	۹۰.۹۱	۹۱.۲۹
	۲۵۰	۹۰.۳	۸۹.۷	۸۷.۷۶	۸۶.۶۴	**۹۳.۵۵**	**۹۳.۷۸**	۹۰.۵۲	۹۰.۰۲
مدل پیشنهادی		**۹۱.۸**	**۹۱.۵**	**۹۱.۸۷**	**۹۰.۶۴**	۹۱.۶۵	۹۲.۵۹	**۹۱.۷۴**	**۹۱.۵۶**

جدول ۲. نتایج آزمایش‌ها برروی مجموعه داده سینماتیکت (نقدهای فیلم‌های سینمایی)

مدل/ معیار		دقت		فراخوانی		صحت		امتیاز F1	
	ابعاد تعبیه‌ساز کلمات	۵-بخشی	۱۰-بخشی	۵-بخشی	۱۰-بخشی	۵-بخشی	۱۰-بخشی	۵-بخشی	۱۰-بخشی
CNN	۱۰۰	۹۲.۰۸	۹۲.۶۳	۹۰.۱۰	۹۰.۳۴	۹۴.۸	۹۵.۵۲	۹۲.۳۱	۹۲.۸۱
	۱۵۰	۹۲.۶۷	۹۲.۶۷	۹۰.۴۷	۹۰.۷۸	**۹۵.۴۱**	۹۴.۹۴	۹۲.۸۷	۹۲.۷۷
	۲۰۰	۹۳.۰۸	۹۲.۷۱	۹۱.۶۲	۹۱.۲۸	۹۴.۹	۹۴.۴۶	۹۳.۲۱	۹۲.۷۹
	۲۵۰	۹۲.۳۸	۹۳.۰۴	۹۰.۱۹	۹۰.۹۵	۹۵.۱۷	**۹۵.۶۳**	۹۲.۵۹	۹۳.۱۷
مدل پیشنهادی		**۹۳.۲۵**	**۹۳.۶۷**	**۹۲.۱۶**	**۹۲.۶۴**	۹۴.۵۷	۹۴.۸۹	**۹۳.۳۴**	**۹۳.۷۲**

جدول ۳. مقایسه روش پیشنهادی با کارهای گذشته

مرجع	دقت	فراخوانی	صحت	امتیاز F1
امیری و همکاران [21]	۷۰.۰۱	۶۸	۶۹	۶۹
دشتی‌پور و همکاران [22]	۷۹.۶۸	۷۸	۷۹	۷۶
روشنفکر و همکاران [23]	-------	۵۲.۲	۵۹.۱	۵۵.۴
مدل پیشنهادی	**۹۳.۶۷**	**۹۲.۶۴**	**۹۴.۸۹**	**۹۳.۷۲**

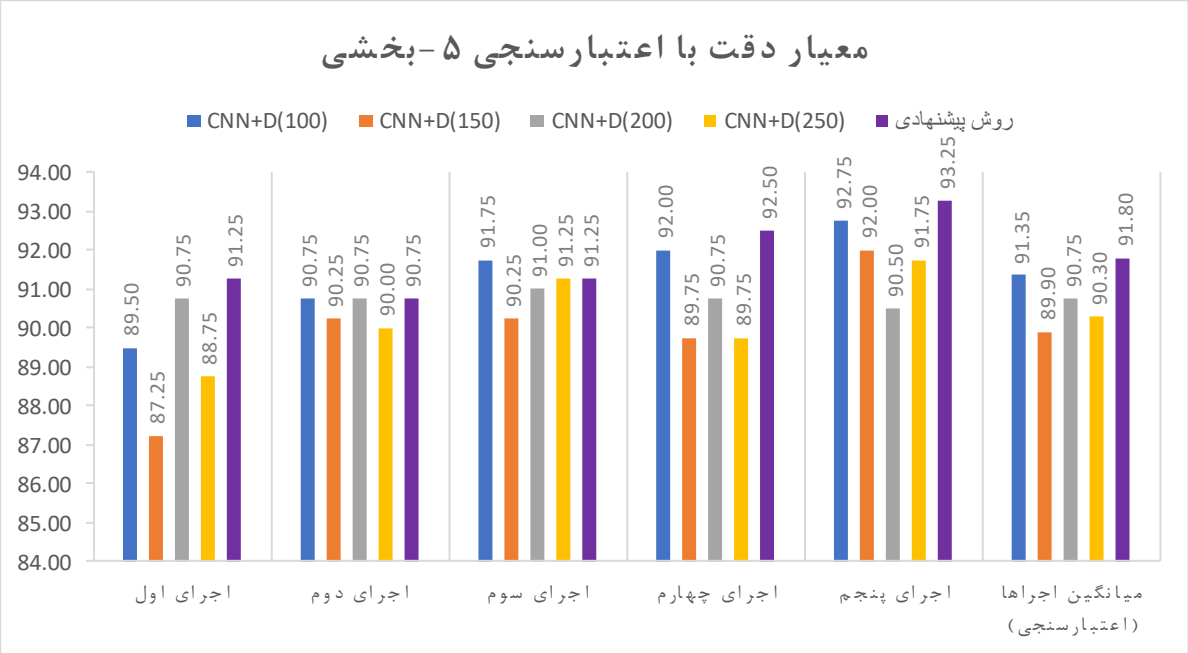

شکل ۴. مقایسه معیار دقت در اجراهای مختلف با اعتبارسنجی ۵-بخشی در مجموعه داده دیجی‌کالا

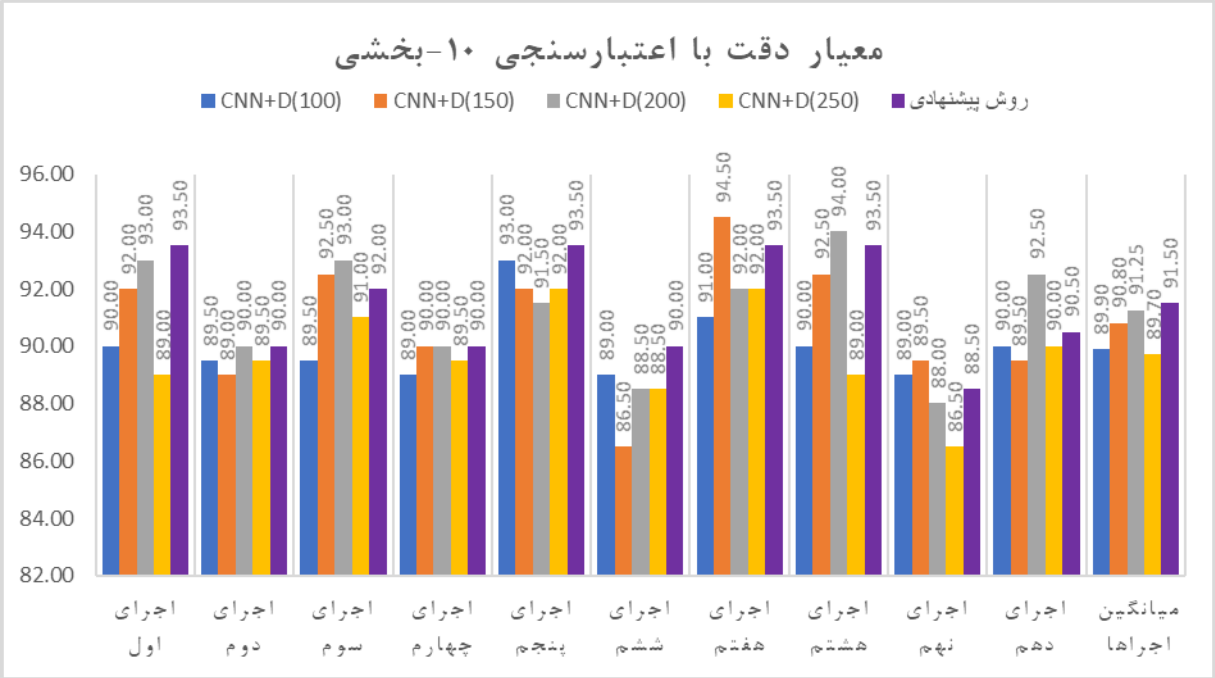

شکل ۵. مقایسه معیار دقت در اجراهای مختلف با اعتبارسنجی ۱۰-بخشی در مجموعه داده دیجی‌کالا

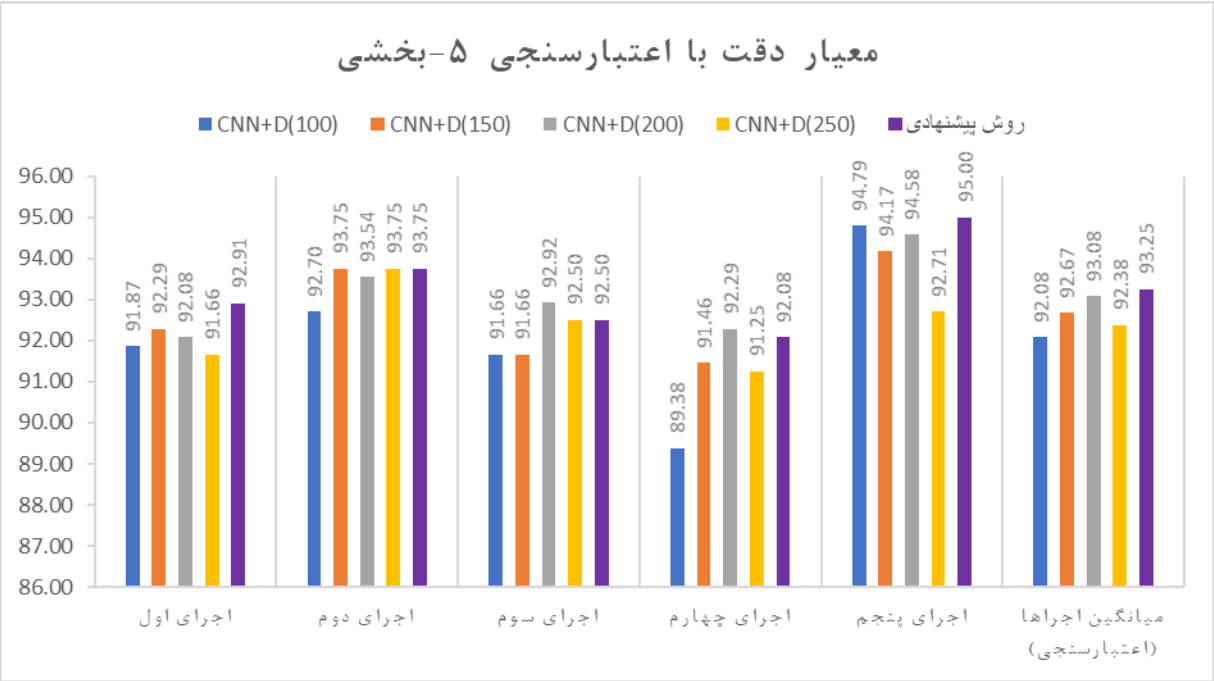

شکل ۶. مقایسه معیار دقت در اجراهای مختلف با اعتبارسنجی ۵-بخشی در مجموعه داده سینماتیکت

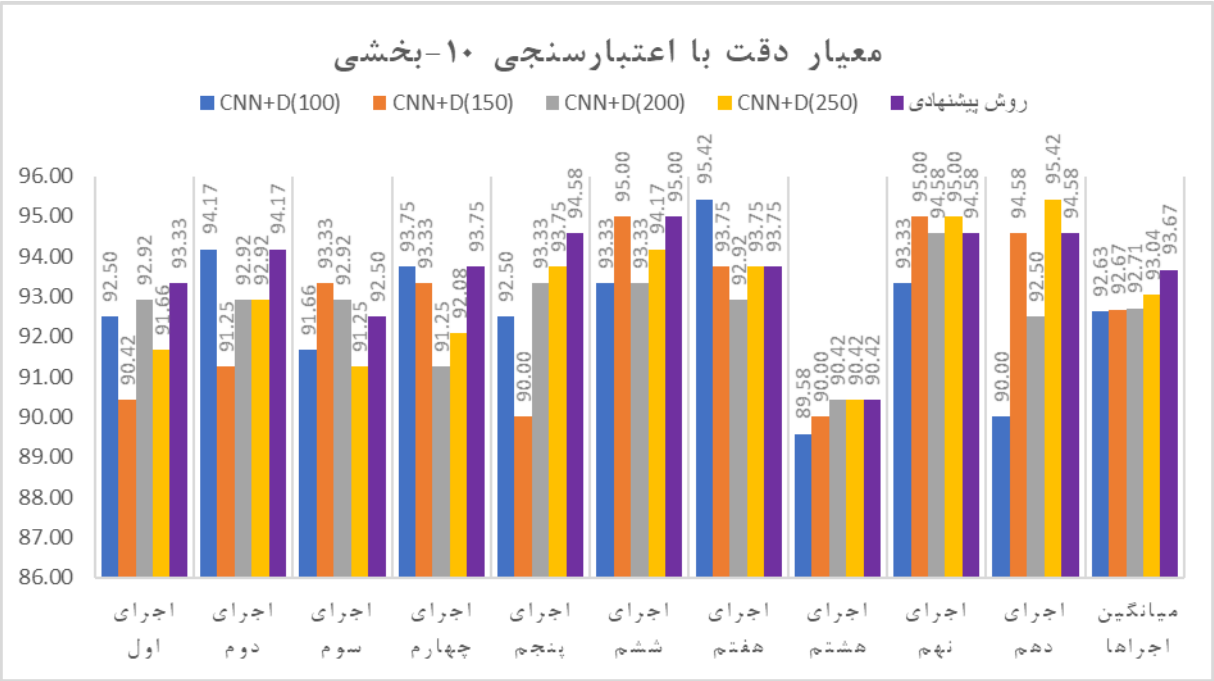

شکل ۷. مقایسه معیار دقت در اجراهای مختلف با اعتبارسنجی ۱۰-بخشی در مجموعه داده سینماتیکت

۶. نتیجه‌گیری

در این مقاله، به‌منظور افزایش کارآیی مدل‌های یادگیری عمیق در حل مساله تحلیل احساسات در زبان فارسی از یادگیری گروهی مبتنی‌بر رویکرد رای اکثریت استفاده شد. در این راستا، چهار شبکه عصبی کانولوشنی پایه ایجاد شد که از لحاظ معماری یکسان هستند پارامتر ابعاد لالایه تعبیه‌ساز آن‌ها متفاوت است. مدل پیشنهادی برروی دو مجموعه داده نقدهای فارسی در زمینه محصولالات و تنها
الکترونیکی و فیلم‌های سینمایی توسط اعتبارسنجی متقابل ۵-بخشی و ۱۰-بخشی با معیارهای معمول طبقه‌بندی یعنی دقت، صحت، فراخوانی و امتیاز F1 ارزیابی شد. نتایج تجربی بدست آمده نشان می‌دهد که مدل یادگیری عمیق مبتنی بر یادگیری گروهی نتایج بهتری را در مقایسه با مدل‌ها واحد از نشان می‌دهد. به عبارت دیگر، ترکیب چندین مدل با هم توانسته است خطاهای تصادفی یکدیگر را کاهش داده و تصمیم درست را تقویت کند.

References

[1] Pathak A.R, Agarwal B, Pandey M, Rautaray S, 2020. Application of Deep Learning Approaches for Sentiment Analysis. Algorithms for Intelligent Systems, pp.1–31.
[2] Laskari N, Sanampudi S, 2016. Aspect Based Sentiment Analysis Survey. IOSR Journal of Computer Engineering, pp.24-28.
[3] Habimana O, Li Y, Li R, Gu X, Yu G, 2019. Sentiment analysis using deep learning approaches: an overview. Science China Information Sciences.
[4] Onan A, 2020. Sentiment analysis on product reviews based on weighted word embeddings and deep neural networks. Concurrency and Computation: Practice and Experience.
[5] Sachin S, Tripathi A, Mahajan N, Aggarwal S, Nagrath P, 2020. Sentiment Analysis Using Gated Recurrent Neural Networks. SN Computer Science.
[6] Hasan A, Moin S, Karim A, Shamshirband S, 2018. Machine Learning-Based Sentiment Analysis for Twitter Accounts. Mathematical and Computational Applications, p.11.
[7] Liu B, 2012. Sentiment Analysis and Opinion Mining. Williston, Morgan & Claypool.
[8] Liu B, 2015. Sentiment Analysis: Mining Opinions, Sentiments, and Emotions. Cambridge, Cambridge University Press.
[9] Medhat W, Hassan A, Korashy H, 2014. Sentiment analysis algorithms and applications: a survey. Ain Shams Eng J.
[10] Onan A, 2020. Sentiment analysis on product reviews based on weighted word embeddings and deep neural networks. Concurrency Computat Pract Exper.
[11] Li W, Liu P, Zhang Q, Liu W, 2019. An Improved Approach for Text Sentiment Classification Based on a Deep Neural Network via a Sentiment Attention Mechanism. Future Internet.
[12] Tixier A.J.P, 2018. Notes on Deep Learning for NLP. arXiv:1808.09772 [cs].
[13] Minaee S, Azimi E, Abdolrashidi A, 2019. Deep-Sentiment: Sentiment Analysis Using Ensemble of CNN and Bi-LSTM Models. arXiv:1904.04206 [cs, stat].
[14] Vazan, M., & Razmara, J. (2021). Jointly Modeling Aspect and Polarity for Aspect-based Sentiment Analysis in Persian Reviews. arXiv preprint arXiv:2109.07680.
[15] Xu D, Tian Z, Lai R, Kong X, Tan Z, Shi W, 2020. Deep learning based emotion analysis of microblog texts. Information Fusion, pp.1–11.
[16] Mohammadi A, Shaverizade A, 2021. Ensemble deep learning for aspect-based sentiment analysis, International Journal of Nonlinear Analysis and Applications, pp.29-38.
[17] Ganaie M.A, Hu M, Tanveer M, Suganthan P.N, 2021. Ensemble deep learning: A review. arXiv:2104.02395 [cs].
[18] Sagi O, Rokach L, 2018. Ensemble learning: A survey. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery.
[19] Ahmad I, Yousaf M, Yousaf S, Ahmad M.O, 2020. Fake News Detection Using Machine Learning Ensemble Methods. Complexity, pp.1–11.
[20] Basiri M.E, Kabiri A, 2017. Sentence-level sentiment analysis in Persian. In Proceedings of the 2017 3rd International Conference on Pattern Recognition and Image Analysis (IPRIA), Shahrekord, Iran, pp.84–89.
[21] Amiri F, Scerri S, Khodashahi M, 2015. Lexicon-based sentiment analysis for Persian Text. In Proceedings of the International Conference Recent Advances in Natural Language Processing, Hissar, Bulgaria, pp.9–16.
[22] Dashtipour K, Ieracitano C, Carlo Morabito F, Raza A, Hussain A, 2020. An ensemble based classification approach for persian sentiment analysis. Progresses in Artificial Intelligence and Neural Systems, pp.207–215.
[23] Roshanfekr B, Khadivi S, Rahmati M, 2017. Sentiment analysis using deep learning on Persian texts, 2017 Iranian Conference on Electrical Engineering (ICEE), pp.1503-1508.
[24] Dashtipour K, Gogate M, Adeel A, Larijani H, Hussain A, 2021. Sentiment Analysis of Persian Movie Reviews Using Deep Learning. Entropy.

View publication stats