مباحث ویژه ۱:

مباحث ویژه ۲:

مباحثی در علوم کامپیوتر:

اصول علم داده

مدرس: میلاد وزان

نیمسال دوم ۱۴۰۲-۱۴۰۱

مقدمه و معرفی درس

"آن‌که همیشه شاگرد می‌ماند، آموزگارِ خویش را پاداشی به‌سزا نمی‌دهد."

فردریش نیچه | چنین گفت زرتشت

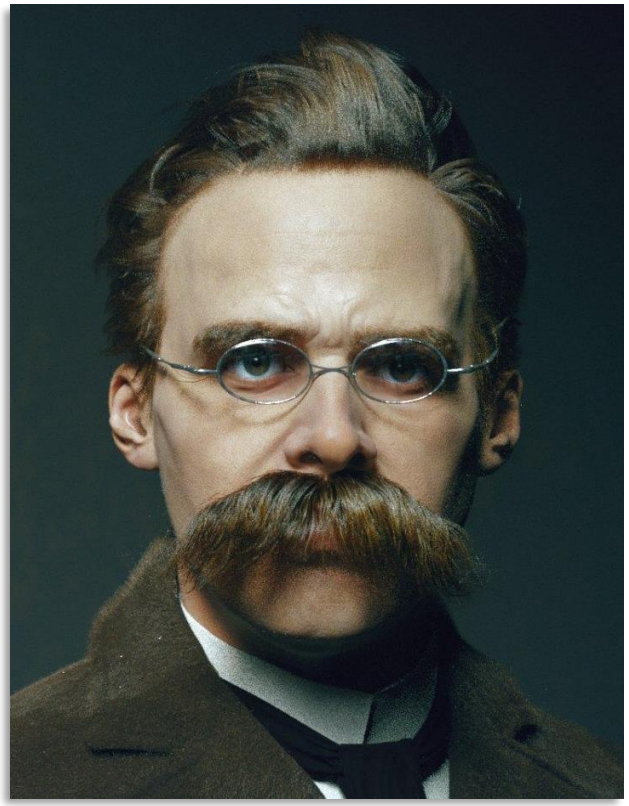

آن‌چه در این درس خواهید آموخت:

- **آشنایی با مفاهیم علم داده**
  - علم داده چیست؟
  - علم داده و ارتباط آن با تجزیه و تحلیل داده، یادگیری ماشین، هوش مصنوعی و کلان داده
  - انواع مختلف تحلیل داده‌ها
  - آشنایی با انوع داده و پیش‌پردازش داده‌ها
- **پایتون**
  - آشنایی با پایتون و ساخت مدل‌های یادگیری ماشین با آن
- **مبانی یادگیری ماشین**
  - آشنایی با انواع مختلف یادگیری: یادگیری با ناظر و یادگیری بدون ناظر
  - انتخاب و ارزیابی مدل
  - انواع دسته‌بندی و معرفی چند الگوریتم مرتبط با آن
  - انواع رگرسیون
  - مقدمه‌ای بر شبکه‌های عصبی عمیق: MLP، CNN و LSTM
  - خوشه‌بندی

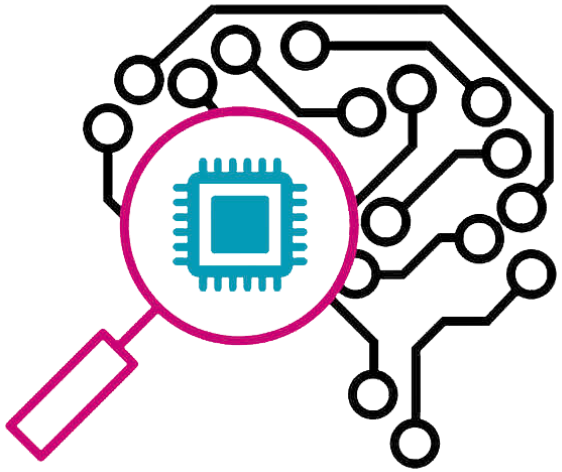

منابع و مراجع

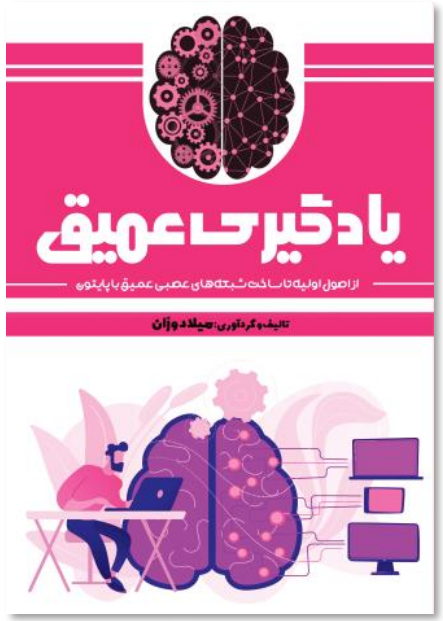

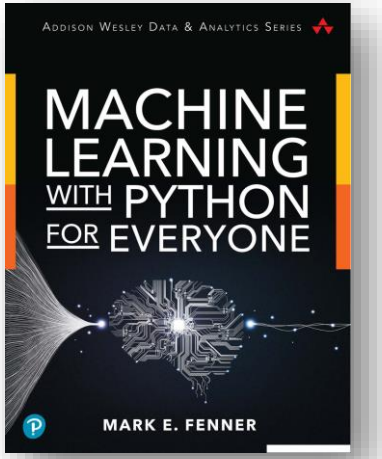

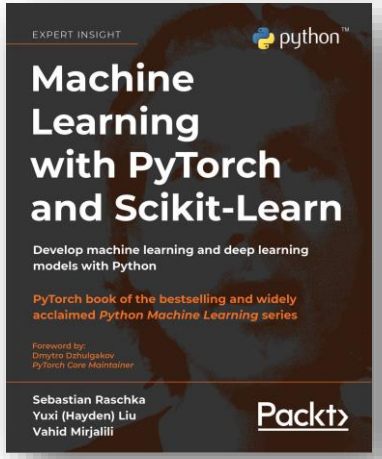

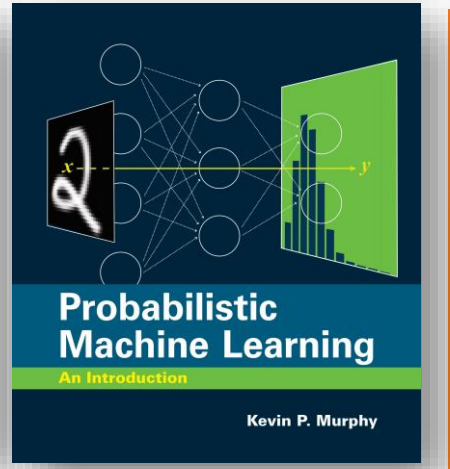

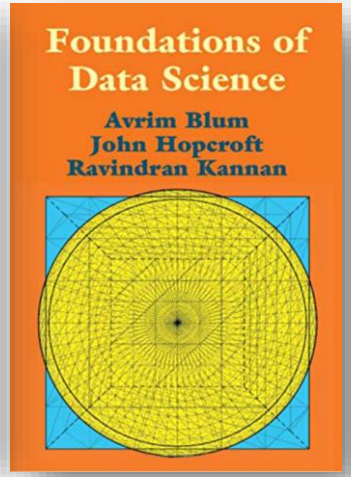

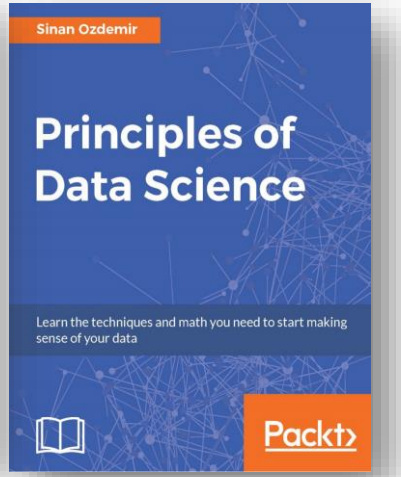

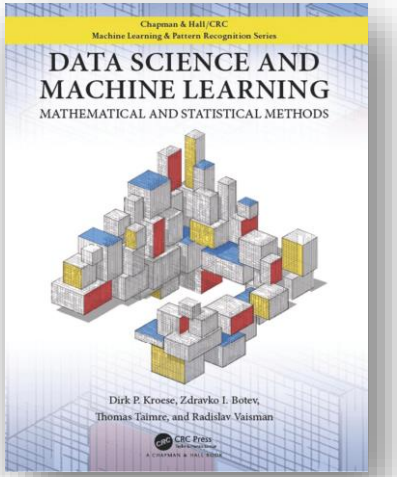

تارنمای درس: http://ds.miladvazan.ir

تعریف (علم داده). زمینه‌ی تحقیقاتی است که با ترکیبی از ابزارهای مختلف، الگوریتم‌ها، یادگیری ماشین، متن‌کاوی، ریاضیات و آمار به کشف الگوهای پنهان از داده‌های خام می‌پردازد.

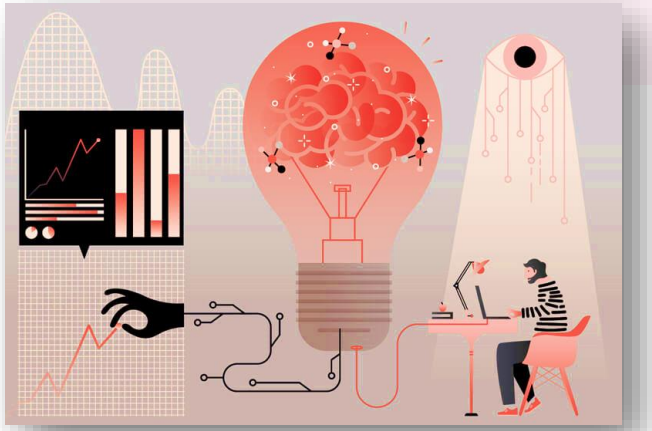

علم داده در مورد استفاده از داده‌ها برای بدست آوردن بینش‌های جدید است که در صورت عدم استفاده‌ی از آن، آن‌ها را از دست می‌دادید.

به عنوان مثال، تصور کنید با سه نفر دیگر دور یک میز نشسته‌اید. شما چهار نفر باید بر اساس برخی داده‌ها تصمیمی بگیرید. چهار نظر برای بررسی وجود دارد. شما می‌توانید از علم داده استفاده کنید تا نظر پنجم، ششم و حتی هفتم را به جدول بیاورید.

به همین دلیل است که علم داده جایگزین مغز انسان نمی‌شود، بلکه آن را تکمیل می‌کند و در کنار آن کار می‌کند. علم داده نباید به عنوان یک راه‌حل نهایی برای مسائل داده ما در نظر گرفته شود. این صرفا یک نظر است، یک نظر کاملا آگاهانه. اما با این وجود این‌که یک نظر است، لیاقت نشستن دور میز را دارد.

چرا از علم داده استفاده می‌کنیم؟

- **حجم بسیار زیاد داده‌ها، تجزیه و تحلیل آن را در یک زمان معقول برای انسان به معنای واقعی غیرممکن می‌کند.**
- **داده‌ها به اشکال مختلف و از منابع مختلف جمع‌آوری می‌شوند و اغلب به‌صورت بسیار سازمان‌دهی نشده ارائه می‌شوند.**
- **داده ها ممکن است ناقص یا اشتباه باشند.**
- **اغلب، ما داده‌هایی در مقیاس‌های بسیار متفاوت داریم و این مقایسه آن‌ها را دشوار می‌کند.**

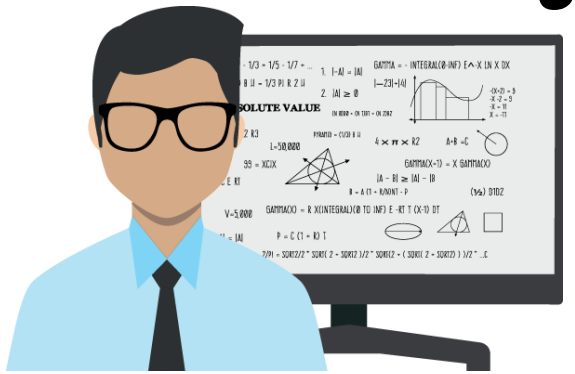

هنگامی که داده‌های خود را تمیز می‌کنیم، روابط بین داده‌ها آشکارتر می‌شود و دانشی که زمانی در اعماق میلیون‌ها ردیف داده مدفون بود، به سادگی بیرون می‌آید.

↓

یکی از اهداف اصلی علم داده کشف این روابط در داده‌ها است.

هدف علم داده **توضیح فرآیندها** از طریق داده‌های موجود است. انتظار می‌رود این توضیح به اندازه کافی دقیق باشد تا بتواند پیش‌بینی انجام دهد. هدف نهایی از این تفسیرها و توضیحات این است که تصمیماتی آگاهانه بر اساس دانش استخراج شده از این داده‌ها انجام دهیم.

چرا علم داده را یاد بگیریم؟

- **در قرن بیست‌ویکم، نیروی محرکِ جدیدی که همان داده‌ها هستند بر صنایع تاثیرگذاشته است.**
- **داده‌ها هر جنبه‌ای از هر چیزی که ما می‌دانیم و انجام می‌دهیم را نشان می‌دهند و اطراف ما را احاطه کرده‌اند.**
- **امروزه علم داده را می‌توان نیروی برقی دانست که به صنایع قدرت می‌دهد و انقلاب عظیمی را تقریبا در تمام صنایع به ارمغان آورده است.**
  - صنایع به داده‌ها نیاز دارند تا عملکرد خود را بهبود ببخشند.
  - رشد کسب‌وکار خود را افزایش دهند.
  - محصولات بهتری برای مشتریان خود فراهم کنند.

هرچند که اکثر سازمان‌ها به **داده‌ها** برای پیشبرد تصمیمات تجاری خود تاکید دارند، اما داده‌ها به تنهایی هدف نیستند. اگر نتوان بینش ارزشمندی که منجر به اقدامات آگاهانه‌تر می‌شود را بدست آورد، حقایق و ارقام بی‌معنی هستند.

↓

صنایع در حال تبدیل شدن به **داده‌محوری** هستند و به دانشمندان داده نیاز دارند تا از آن‌ها در تصمیم‌گیری‌های هوشمندانه و ایجاد محصولات بهتر کمک بگیرند.

علم داده کلید آینده است. باید پویا باشیم، با تکنولوژی کار کنیم و به جلو حرکت کنیم و قبل از اینکه خیلی دیر شود، علم داده را بیاموزیم.

چرا علم داده را یاد بگیریم؟

- **شغلی پرخواستار**
  - امروزه داده‌ها بدون شک از با ارزش‌ترین کالاها هستند. کسب‌وکارهای پیشرو، از جمله گوگل، آمازون و متا، از داده‌ها برای افزایش سودآوری و دستیابی به اهداف استراتژیک استفاده می‌کنند. مسئله این است که داده‌ها در مکان‌های مختلفی به دو شکل ساختاریافته و بدون‌ساختار پخش می‌شوند. به منظور جمع‌آوری داده‌ها، تجزیه و تحلیل آن‌ها، بدست آوردن بینش مفید و ارائه آن برای تصمیم‌گیری آگاهانه کسب و کار، **شرکت‌ها به علم داده و افراد نیاز دارند و همیشه خواهند داشت.**
- **چشم‌انداز رشد آینده**
  - فرصت‌ها در زمینه علم داده بسیار زیاد است، جایی که **تقاضا به‌طور مرتب از عرضه پیشی می‌گیرد.** بر اساس نظرسنجی منتشر شده توسط اداره آمار کار ایالات متحده، تقریباً 11.5 میلیون شغل اضافی در زمینه علم داده تا سال 2026 وجود خواهد داشت که افزایشی حدود 28 درصدی را نشان می‌دهد. حتی در گزارش آینده‌ی کار مجمع جهانی اقتصاد در سال 2020 پیش‌بینی شده است که تا سال 2025، دانشمندان داده جایگاهی را با بالاترین رشد و تقاضا خواهند داشت.
- **بسته‌های پرداختی زیاد**
- حتی پس از در نظر گرفتن فرصت‌ها برای پیشرفت، امکان‌سنجی مالی یک حرفه در انتخاب اینکه آیا آن را دنبال کنید، یک ملاحظه‌ی اساسی است. طبق گفته Glassdoor، متوسط دستمزد در ایالات متحده 49800 دلار است، در حالی که میانگین دستمزد متخصصان علوم داده 108000 دلار است که بیش از دو برابر میانگین ملی است.

دانشمند داده

تعریف (دانشمند داده). یک دانشمند داده کسی است که می‌داند چگونه معنا را از داده‌ها استخراج و تفسیر کند. به عبارت دیگر، آن‌ها نسل جدیدی از متخصصین تحلیل‌گر داده‌ها هستند که مهارت‌های فنی برای حل مسائل پیچیده را دارند و همچنین کنجکاو در کشف مسائلی هستند که باید حل شوند. او زمان زیادی را صرف جمع‌آوری، تمیز کردن و بازسازی داده‌ها (Data munging) می‌کند، زیرا داده‌ها هرگز تمیز نیستند.

یک دانشمند داده‌ها نه تنها مشکلات و مسائل را حل می‌کند، بلکه مشکلات را در وهله اول نیز شناسایی می‌کند.

تعریف (بازسازی داده-Data munging). فرآیند تبدیل داده‌های خام به فرمت قابل استفاده‌تر است. به عبارت دیگر، فرآیند اولیه پالایش داده‌های خام به محتوا یا قالب‌هایی است که برای مصرف کاربران مناسب‌تر است. بازسازی داده‌ها به کسب و کارها این امکان را می‌دهد تا با داده‌های پیچیده‌تر در زمان کم‌تری مقابله کنند، نتایج دقیق‌تری تولید کنند و تصمیمات بهتری بگیرند.

تحلیل داده‌های "خام" اغلب سخت و حتی غیرممکن است که بتوان از آن‌ها بینش مفیدی بدست آورد. این‌جا جایی است که کسی فیلدها، ردیف‌ها و ستون‌ها را به قالب مفیدتری تبدیل می‌کند.

دانشمند داده

کار یک دانشمند داده، ارائهِ دقیق‌ترین پیش‌بینی‌ها است. این کار نیاز به استفاده از فن‌آوری‌های پیشرفته تجزیه و تحلیل، از جمله یادگیری ماشین و مدل‌سازی پیش‌گویانه دارد. نقش دانشمند داده، مجموعه‌ای از چندین نقش فنیِ سنتی است، از جمله ریاضیدان، متخصص آمار و متخصص کامپیوتر.

بینش آن‌ها معمولا **آینده‌نگر** است. این به این معنی است که آن‌ها داده‌های گذشته مربوط را ارزیابی می‌کنند و بینش‌هایی را استخراج می‌کنند که می‌تواند به عنوان پایه‌ای برای ایجاد تغییرات بالقوه در رفتار یا روند مصرف‌کننده استفاده شود. این به سازمان‌ها امکان می‌دهد تا با راهبردهای بلند مدت ظاهر شوند.

کلان داده

تعریف (کلان داده). ترکیبی از داده‌های ساختاریافته، نیمه ساختاریافته و بدون‌ساختار است که توسط سازمان‌ها جمع‌آوری می‌شوند و می‌توانند برای استخراج اطلاعات استفاده شوند و در پروژه‌های یادگیری ماشین، مدل‌سازی پیش‌گویانه و دیگر برنامه‌های تحلیلی پیشرفته مورد استفاده قرار گیرند.

این مجموعه داده‌ها آنقدر حجیم هستند که نرم‌افزارهای سنتی پردازش داده نمی‌توانند آن‌ها را مدیریت کنند.

کلان داده از منابع بی‌شماری بدست می‌آید. برخی از نمونه‌ها عبارتند از: سیستم‌های پردازش تراکنش، پایگاه‌های داده مشتریان، اسناد، ایمیل‌ها، سوابق پزشکی، برنامه‌های تلفن همراه و شبکه‌های اجتماعی. همچنین شامل داده‌های تولید شده توسط ماشین‌ها، مانند فایل‌های گزارش شبکه و سرور، تجهیزات صنعتی و دستگاه‌های اینترنت اشیا است.

تفاوت علم داده با کلان داده (کلان داده: نفت خام علم داده: پالایش نفت خام)

- کلان داده بیشتر به فناوری هایی در علوم کامپیوتر مانند رایانش ابری، ابزارهای پردازش جریانی، و غیره اشاره دارد که برای مدیریت مجموعه داده‌های بسیار بزرگ که نیاز به تکنیک‌های تخصصی به منظور استفاده بهینه از داده‌ها دارند، مورد استفاده قرار می‌گیرند.
- از سوی دیگر، علم داده یک زمینه مطالعاتی است، یک اصطلاح کلی که تمام تکنیک‌ها و ابزارهای متمرکز بر تجزیه و تحلیل داده‌ها را در بر می‌گیرد. علم داده یک رویکرد علمی است که ایده‌های الگوریتمی، محاسباتی و ابزارهای رایانه‌ای را برای پردازش این داده‌های بزرگ اعمال می‌کند.
- کلان داده اساسا یک کاربرد ویژه از علم داده است که در آن مجموعه داده‌ها بسیار بزرگ است و نیاز به غلبه بر چالش‌های منطقی برای مقابله آن‌ها دارد.

کلان داده مفید است، اما علم داده است که آن را قدرتمند می‌کند.

علم داده بر روی داده‌های بزرگ کار می‌کند تا از طریق تجزیه و تحلیل پیش‌گویانه نتایج مفیدی بدست آورد که در آن نتایج برای اتخاذ تصمیمات هوشمندانه مورد استفاده قرار می‌گیرند.

تفاوت اساسی بین کلان داده و علم داده را می‌توان با ذکر یک مثال بهتر درک کرد. علم داده همانند یک کتاب است که در آن شما می‌توانید یک راه حل برای مشکلات خود پیدا کنید. از سوی دیگر، کلان داده را می‌توان به عنوان یک کتابخانه بزرگ در نظر گرفت که در آن پاسخ‌های تمام سوالات در آنجا هستند، اما یافتن پاسخ به سوالات شما دشوار است.

تجزیه و تحلیل داده

تعریف (تجزیه و تحلیل داده). فرآیند جمع‌آوری، مدل‌سازی و تحلیل داده‌ها برای استخراج بینش‌هایی است که در تصمیم‌گیری‌ها، کمک‌کننده هستند.

یک مثال ساده از تجزیه و تحلیل داده‌ها را می توان در زندگی روزمره خودمان مشاهده کنیم، هر زمانی که تصمیمی را با ارزیابی آنچه در گذشته اتفاق افتاده می‌گیریم، یا اینکه اگر آن تصمیم را بگیریم چه اتفاقی خواهد افتاد.

شرلوک هولمز در رسوایی در بوهم اثر سر آرتور کانن دویل اعلام می‌کند:

"این یک اشتباه بزرگ است که قبل از دستیابی به داده‌ها نظریه‌پردازی کنیم. [در این صورت] انسان به‌طور نامحسوسی، به جای نظریه‌هایی که مطابق با واقعیت‌ها باشند، شروع به تحریف (تغییر) حقایق می‌کند تا مطابق با نظریه‌ها باشد."

این ایده در ریشه تجزیه و تحلیل داده‌ها نهفته است. وقتی بتوانیم از داده‌ها معنا استخراج کنیم، به ما این قدرت را می‌دهد تا تصمیمات بهتری بگیریم.

تحلیل‌گر داده

تعریف (تحلیل‌گر داده). تحلیل‌گر داده کسی است که اطلاعات را با استفاده از ابزارهای تجزیه و تحلیل داده‌ها بررسی و موشکافی می‌کند. به عبارت دیگر، آن‌ها وظیفه جمع‌آوری، پردازش و انجام تحلیل‌های آماری داده‌ها را بر عهده دارند. نتایج معنی‌داری که آن‌ها از داده‌های خام به دست می‌آورند به کارفرمایان یا مشتریانشان کمک می‌کند تا با شناسایی حقایق و روندهای مختلف تصمیم‌های مهمی بگیرند.

مسئولیت‌های اصلی یک تحلیل‌گر داده:

- استفاده از ابزارهای خودکار برای استخراج داده‌ها و سپس سازماندهی مجدد داده‌ها در قالبی که به راحتی توسط انسان یا ماشین قابل خواندن باشد.
- حذف داده‌های خراب
- استفاده از ابزارهای آماری برای شناسایی، تجزیه و تحلیل و تفسیر الگوها و روندها در مجموعه داده‌های پیچیده که می‌تواند برای تشخیص و پیش‌بینی مفید باشد.

تفاوت تحلیل‌گر داده با دانشمند داده

- در حالی که تحلیل‌گر داده‌ها با حل مسائل سر و کار دارد، یک دانشمند داده، مشکلات را شناسایی کرده و سپس آن‌ها را حل می‌کند.
- تحلیل‌گر داده‌ها با توسعه مدل‌سازیِ پیشگویانه یا ابزار آماری برای پیش‌بینی داده‌ها سروکار ندارد. با این حال، دانشمندان داده نیاز به دانش یادگیری ماشین برای ساخت مدل‌های پیش‌بینی قدرتمند دارند. این مدل‌های پیش‌بینی مدل‌های رگرسیون و دسته‌بندی هستند.
- دانشمندان داده نیاز به تنظیم مدل‌های داده در جهت ایجاد بهتر محصولات داده‌ها دارند. همچنین نیازمند بهینه‌سازی عملکرد مدل‌های یادگیری ماشین است. این مورد توسط تحلیل‌گران داده‌ها مورد نیاز نیست. بنابراین، نقش یک دانشمند داده نه تنها شامل ساخت مدل‌ها، بلکه تنظیم و حفظ آن‌ها نیز می‌شود.

تجزیه و تحلیل داده و علم داده همپوشانی قابل توجهی با یک‌دیگر دارند و در عین حال کاملا از هم متمایز هستند. **تحلیل‌گران داده بر روی اینجا و اکنون تمرکز می‌کنند، در حالی‌که دانشمندان داده آنچه را که ممکن است اتفاق بیافتد را پیش‌بینی می‌کنند.**

یک دانشمند داده کسی است که می‌تواند آینده را بر اساس الگوهای گذشته پیش بینی کند، در حالی که یک تحلیل‌گر داده کسی است که فقط بینش‌های معنی‌دار را از داده ها ارائه می‌دهد.

از یک دانشمند داده انتظار می‌رود که سؤالات خود را ایجاد کند در حالی که یک تحلیلگر داده پاسخ مجموعه‌ای از سؤالات را از داده‌ها پیدا می‌کند.

در بسیاری از سناریوها، از تحلیلگران داده انتظار نمی‌رود که تجربه یادگیری ماشین عملی داشته باشند یا مدل‌های آماری بسازند، اما مسئولیت اصلی یک دانشمند داده ساخت مدل‌های آماری و تسلط کامل به یادگیری ماشین است.

انواع تحلیل داده‌ها

تحلیل توصیفی: چه اتفاقی افتاده است

تجزیه و تحلیل توصیفی، ساده‌ترین، رایج‌ترین و اولین گام مهم برای انجام هر فرآیند تحلیلی آماری است و هدف آن پاسخ به سوال است که چه اتفاقی افتاده است؟ به عبارت دیگر توصیفی از آن‌چه در گذشته اتفاق افتاده است را بررسی می‌کند: درآمد ماهانه، فروش شش ماه اخیر، بازدید سالانه‌ی وب‌سایت و غیره. این تحلیل به ما نحوه‌ی توزیع داده‌ها را ارائه می‌دهد، به شناسایی دورریزها کمک می‌کند و ما را قادر می‌سازد تا رابطه‌ی بین متغیرها را شناسایی کنیم.

نکته منفی این تحلیل این است که تجزیه و تحلیل توصیفی یک پدیده را برجسته می‌کند بدون اینکه به‌طور دقیق دلیل وقوع آن را توضیح دهد. به همین دلیل، چنین رویکردی باید همیشه با سایر تجزیه و تحلیل‌ها ترکیب شود تا منافع واقعی کسب‌وکار شما را بدست آورد.

تجزیه و تحلیل توصیفی فرآیند استفاده از داده‌های فعلی و گذشته برای شناسایی روندها و روابط است. گاهی اوقات آن را ساده‌ترین شکل تحلیل داده می‌نامند زیرا روندها و روابط را توصیف می‌کند اما عمیق‌تر نمی‌شود.

نرم‌افزارهای آماری پایه، مانند مایکروسافت اکسل یا ابزارهای مجسم‌سازی داده‌ها می‌توانند به تحلیل داده‌ها، شناسایی روندها و روابط بین متغیرها و نمایش بصری اطلاعات کمک کنند.

انواع تحلیل داده‌ها

تحلیل تشخیصی: چرا این اتفاق افتاد

با خلاصه کردن ویژگی‌های یک مجموعه داده توسط تجزیه و تحلیل توصیفی که ابتدایی‌ترین شکل تجزیه و تحلیل داده‌ها است، به ما کمک می‌کند تا آنچه اتفاق افتاده است را شناسایی کنیم. با این حال، برای درک عمیق‌تر، ما به تجزیه و تحلیل تشخیصی نیاز داریم. این شامل کاوش عمیق‌تر در داده‌ها برای شناسایی نه تنها آنچه رخ داده است، بلکه چرایی است. این تحلیل تمرکز بر علت و معلول دارد به همین دلیل است که تجزیه و تحلیل تشخیصی گاهی به عنوان تحلیل علت ریشه‌ای شناخته می‌شود.

تجزیه و تحلیل تشخیصی که اغلب به عنوان تجزیه و تحلیل علت ریشه‌ای شناخته می‌شود، یک نوع تجزیه و تحلیل پیشرفته است که یک گام فراتر می‌رود تا داده‌ها و یا محتوا را برای پاسخ به پرسش "چرا این اتفاق افتاد داد؟" بررسی کند.

تحلیل تشخیصی را می‌توان به صورت دستی، با استفاده از یک الگوریتم یا با نرم‌افزارهای آماری (مانند مایکروسافت اکسل) انجام داد.

انواع تحلیل داده‌ها

تحلیل پیش‌گویانه: چه اتفاقی خواهد افتاد

تحلیل پیش‌گویانه به الگوهای داده‌های فعلی و گذشته نگاه می‌کند تا مشخص کند که آیا این الگوها احتمالاً دوباره ظاهر می‌شوند یا خیر. می‌توان از تحلیل پیش‌گویانه برای بهبود کارایی عملیاتی و کاهش ریسک استفاده کرد.

تحلیل پیشگویانه در مورد ناشناخته‌های خاصی در آینده پیش بینی می‌کند.

تجزیه و تحلیل پیش‌بینی می‌تواند با استفاده از الگوریتم‌های آماری و یا الگوریتم‌های یادگیری ماشین انجام شود. در هر صورت، از داده‌های گذشته برای ایجاد فرضیات در مورد آینده استفاده می‌شود.

انواع تحلیل داده‌ها

تحلیل تجویزی: چه اقدامی باید انجام شود

تحلیل تجویزی فرآیند استفاده از داده‌ها برای تعیین یک عمل بهینه است. با در نظر گرفتن تمام عوامل مرتبط، این نوع تجزیه و تحلیل توصیه‌هایی را برای مراحل بعدی ارائه می‌دهد. به همین دلیل، تحلیل تجویزی یک ابزار ارزشمند برای تصمیم‌گیری مبتنی بر داده است.

تحلیل تجویزی "آنچه که ما می‌دانیم می‌گیرد (داده‌ها)"، داده‌ها را برای پیش‌بینی این‌که چه اتفاقی می‌افتد درک می‌کند و بهترین مراحل روبه‌جلو را براساس شبیه‌سازی آگاهانه پیشنهاد می‌کند و مشخص می‌کند که پیامدهای احتمالی هر یک از آن‌ها چیست.

هدف تجزیه و تحلیل تجویزی، که قطعا پیشرفته‌ترین گروه در فهرست ما است، پیشنهاد یک روش عملی برای جلوگیری از مشکلات آینده یا بدست آوردن حداکثر سود از یک روند امیدوارکننده است.

تجزیه و تحلیل تجویزی، پیشرفت طبیعی حاصل از روش‌های تجزیه و تحلیل توصیفی و پیش‌گویانه است و برای حذف حدس‌ورزی از تجزیه و تحلیل داده‌ها، یک گام فراتر می‌رود.

ارتباط علم داده با یادگیری ماشین

تعریف (هوش مصنوعی). شبیه‌سازی هوش طبیعی در ماشین‌هایی است که برای یادگیری و تقلید از اعمال انسان برنامه‌ریزی شده‌اند. این ماشین‌ها می‌توانند با تجربه یاد بگیرند و کارهایی شبیه انسان را انجام دهند.

هوش مصنوعی نیز به این صورت تعریف می‌شود:

- موجودی هوشمند ساخته شده توسط انسان
- قادر به انجام وظایف هوشمندانه بدون دستور صریح
- قادر به تفکر و عمل عقلانی و انسانی

ارتباط علم داده با یادگیری ماشین

تعریف (یادگیری ماشین). یادگیری ماشین به عنوان زیر شاخه‌ای از هوش مصنوعی تعریف می‌شود که به ماشین‌ها توانایی یادگیری خودکار از تجربیات گذشته و داده‌ها برای شناسایی الگوها و ارائه‌ی پیش‌بینی با حداقل مداخله انسانی را می‌دهد. به عبارت دیگر، آن‌ها بدون برنامه‌ریزی صریح از تجربه یاد می‌گیرند و پیشرفت می‌کنند.

یادگیری ماشین، به ماشین می‌آموزد که چگونه بر اساس تجربه گذشته استنتاج و تصمیم بگیرد. الگوها را شناسایی می‌کند و داده‌های گذشته را تجزیه و تحلیل می‌کند تا معنای این نقاط داده را استنتاج کند تا به یک نتیجه‌گیری احتمالی بدون نیاز به دخالت دادن تجربه انسانی برسد. این فناوری برای رسیدن به نتیجه‌گیری با ارزیابی داده‌ها باعث صرفه‌جویی در وقت انسان برای کسب و کارها می‌شود و به آن‌ها کمک می‌کند تا تصمیمات بهتری بگیرند.

یادگیری ماشین با استفاده از الگوریتم‌ها برای شناسایی الگوها و یادگیری، **در یک فرآیند تکراری**، اطلاعات روشنگری را از حجم زیادی از داده‌ها بدست می‌آورد.

ارتباط علم داده با یادگیری ماشین

یادگیری ماشین چگونه کار می‌کند؟

فرآیند یادگیری ماشین با مشاهده داده‌ها که نمونه‌های آموزشی نامیده می‌شوند، آغاز می‌شود. به دنبال الگوهایی در داده‌ها می‌گردد تا بعدا بتواند بر اساس نمونه‌های ارائه شده استنتاج کند.

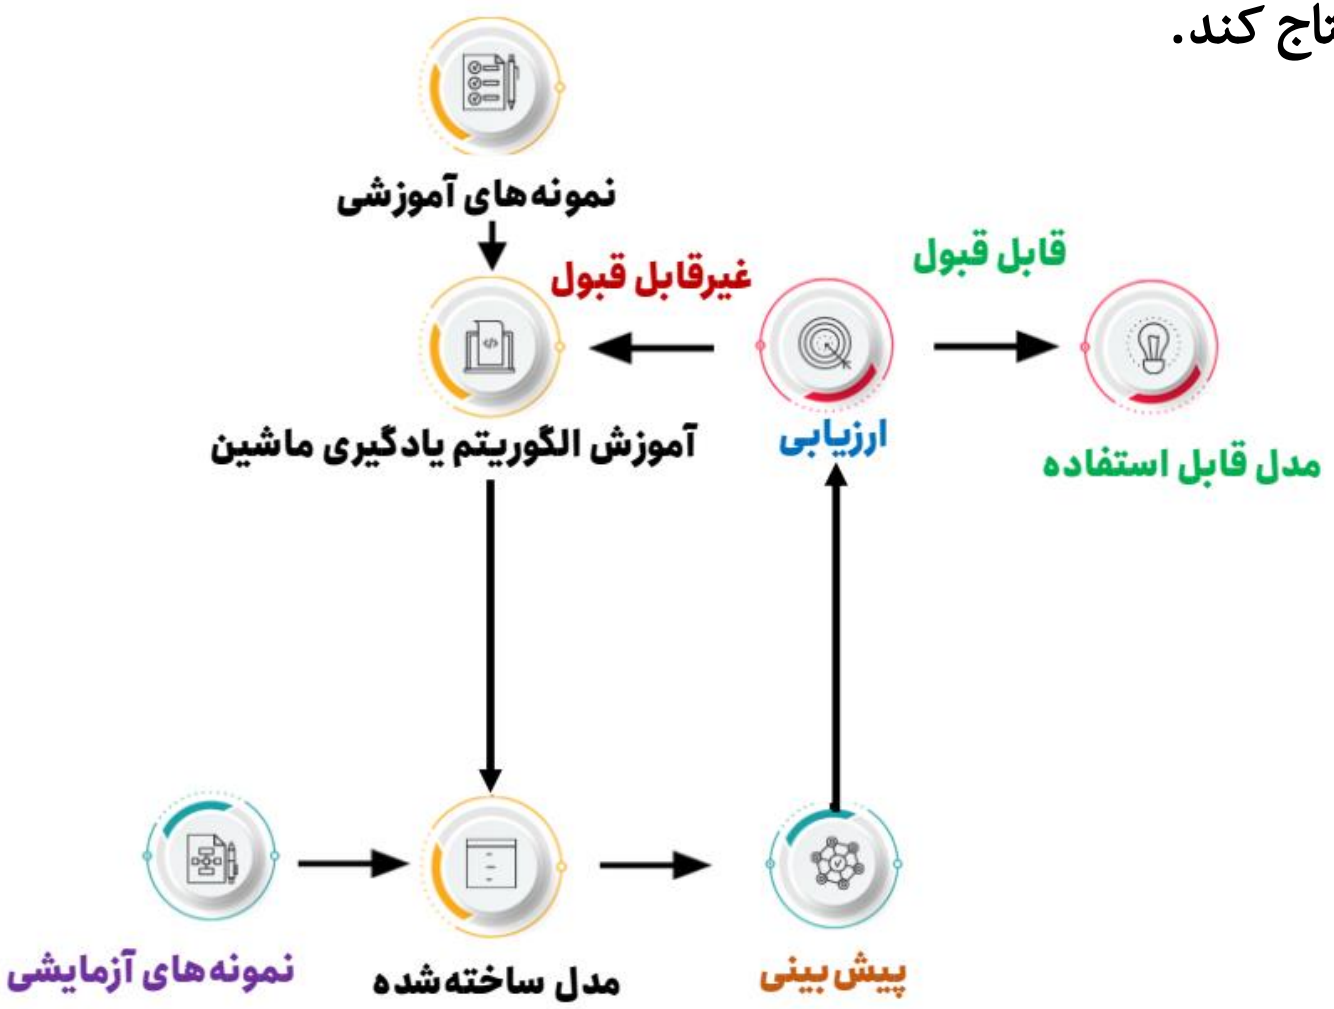

ارتباط علم داده با یادگیری ماشین

- یادگیری ماشین، تنها در صورتی می‌تواند بینش‌های ارزشمندی ارائه دهد که داده‌های با کیفیت را دریافت کند.
- دانشمند داده به یادگیری ماشین نیاز دارد، زیرا درک و پیش‌بینی دقیق نتایج حاصل از حجم عظیمی از داده‌های پیچیده که سازمان‌ها در اختیار دارند، عملا غیرممکن است.

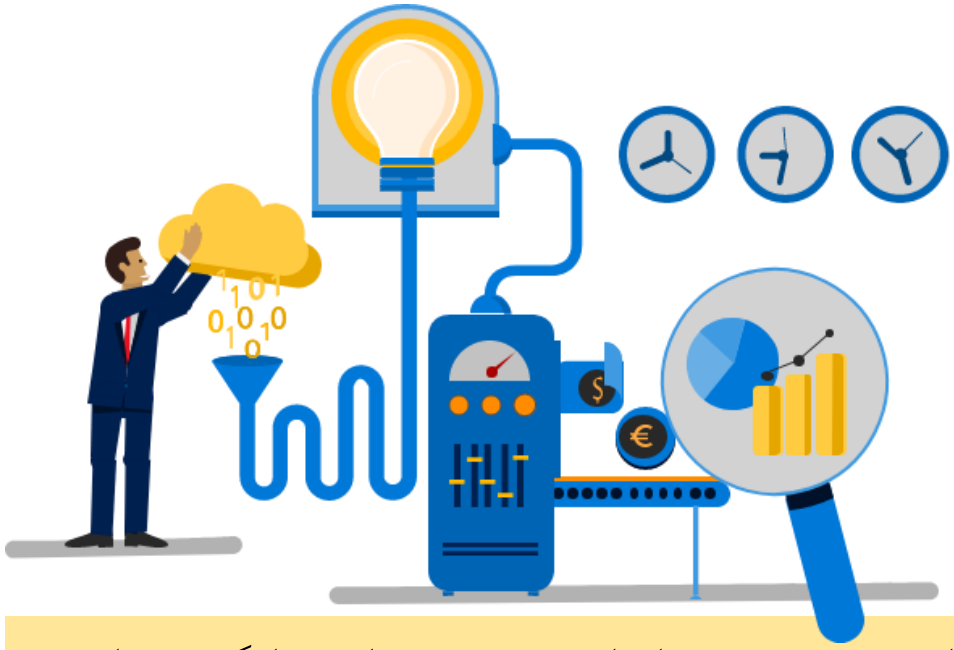

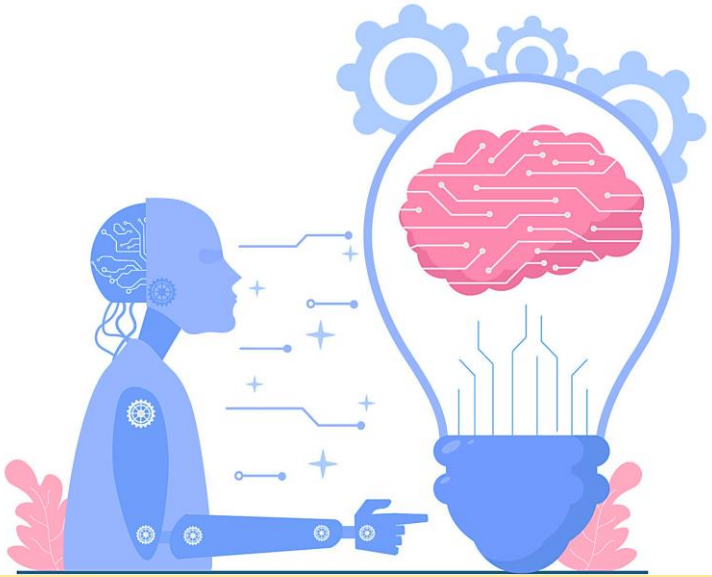

علم داده را می‌توان به عنوان ادغام چندین رشته، از جمله تجزیه و تحلیل داده، مهندسی نرم‌افزار، مهندسی داده، یادگیری ماشین، تحلیل پیش‌گویانه و غیره مشاهده کرد.

تجزیه و تحلیل داده‌ها و یادگیری ماشین دو مورد از ابزارها و فرآیندهایی هستند که علم داده از آن‌ها استفاده می‌کند.

فرآیند علم داده

علم داده یک فرآیند شش مرحله‌ای به شرح زیر است:

۱. **چارچوب بندی مسئله و تعیین هدف تحقیق**

۲. **جمع‌آوری داده‌های خام مورد نیاز برای مسئله**

۳. **پردازش و تمیزسازی داده‌ها را برای تجزیه و تحلیل**

۴. **کاوش داده‌ها**

۵. **تجزیه و تحلیل عمیق (ساخت مدل)**

۶. **اشتراک‌گذاری نتایج تجزیه و تحلیل**

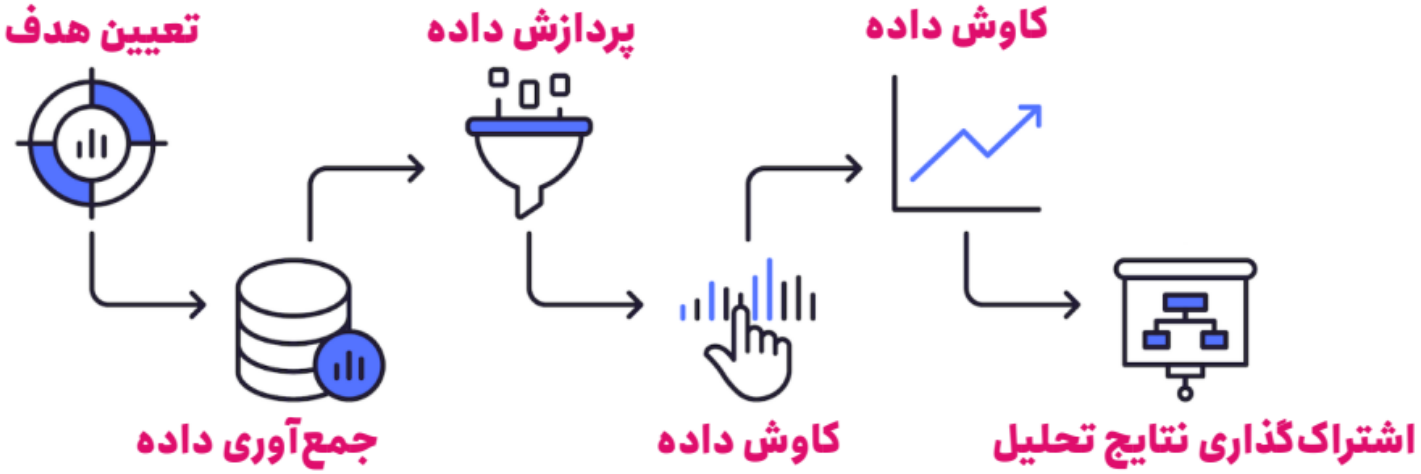
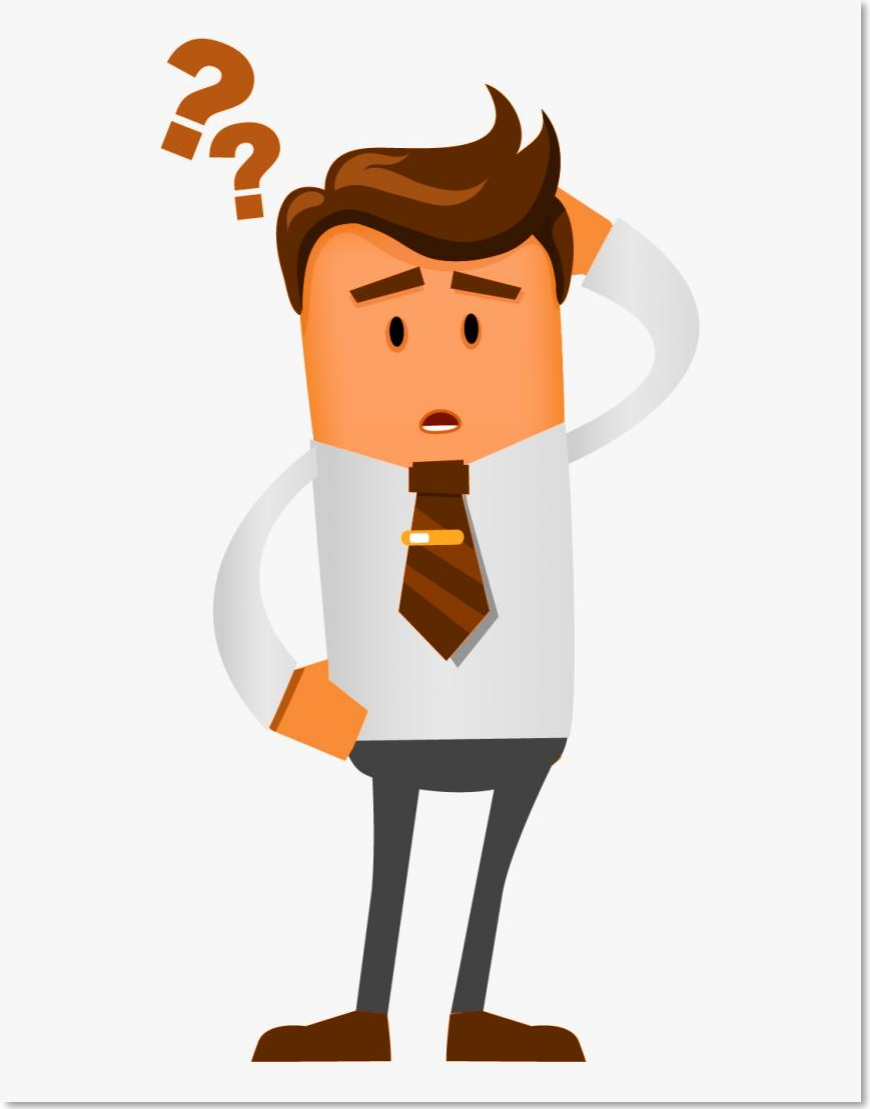
پرسش و پاسخ