Joint Learning for Aspect and Polarity Classification in Persian Reviews Using Multi-Task Deep Learning

Milad Vazan

تحول دیجیتال و سیستم های هوشمند
Digital Transformation and Intelligent Systems
۲۵ و ۲۶ آذرماه ۱۴۰۰

مجتمع آموزش عالی لارستان
Larestan Higher Education Complex

یادگیری توام برای طبقه‌بندی ویژگی و قطبیت در نظرات فارسی با استفاده از یادگیری عمیق چندوظیفه‌ای

میلاد وزان[۱]

[۱]دانشگاه تبریز، گروه علوم کامپیوتر، تبریز m.vazan۹۷@ms.tabrizu.ac.ir

چکیده

هدف اصلی این مقاله متمرکز بر دو زیرمساله مرتبط با تحلیل احساسات مبتنی‌بر ویژگی یعنی، تشخیص مقوله ویژگی (ACD) و قطبیت مقوله ویژگی (ACP) در زبان فارسی است. روش‌های قبلی در حل این مسائل در بسیاری از زبان‌ها، آن‌ها را به‌عنوان دو مساله جداگانه بیان کرده و به حل آن‌ها می‌پردازند. در این مقاله، ما یک مدل یادگیری چندوظیفه‌ای مبتنی‌بر شبکه‌های عمیق را پیشنهاد می‌دهیم، که می‌تواند به‌صورت توام (مشترک) مقوله ویژگی و قطبیت آن را شناسایی و استخراج کند. در راستای این کار و برای مقایسه، از چندین شبکه عمیق همانند، CNN، LSTM، Bi-LSTM و GRU استفاده گردید. روش پیشنهادی با استفاده از یک مجموعه داده منحصربه‌فرد از نظرات ارائه شده در خصوص فیلم‌های فارسی مورد ارزیابی قرار گرفت که در پایان مدل CNN بهترین عملکرد را در معیارهای ارزیابی دقت زیرمجموعه و شاخص جاکارد، به ترتیب با نمره‌های ۶۷.۵٪ و ۷۷.۰۷۵٪ به‌دست آورد.

واژه‌های کلیدی

یادگیری عمیق، تحلیل احساسات مبتنی‌بر ویژگی، یادگیری چندوظیفه‌ای، تشخیص مقوله ویژگی، قطبیت مقوله ویژگی

---

۱. مقدمه

با افزایش ابزارهای وب ۲ و ظهور رسانه‌های اجتماعی، زندگی امروز بشر با آن پیوند عمیقی خورده است. همین امر منجر به تولید حجم عظیمی از داده‌ها توسط کاربران این رسانه‌ها شده است. داده‌های متنی یکی از پرمصرف‌ترین‌ها است که می‌تواند برای بدست آوردن اطلاعات مهم در موضوعات مختلف مورد استفاده قرار گیرد. رسانه‌های اجتماعی در اشکال مختلف آن مانند، وبلاگ ، میکروبلاگ و شبکه‌های اجتماعی، بستری را برای تعامل، گفت‌وگو، درج ایده‌ها و نظرات ایجاد کرده‌اند. نظرات ارائه شده کاربران در شبکه‌های اجتماعی بسیار مهم و کابردی هستند. در یک فروشگاه برخط، نظرات و دیدگاه‌های مختلف در مورد یک محصول می‌تواند سطح رضایت و کیفیت مشتری را منعکس سازد که این می‌تواند راهنمای بسیار خوبی برای سایر خریداران باشد. در سایر کاربردها، این نظرات برخط می‌تواند به دولت‌ها و نهادهای سیاسی در بازخورد افکار عمومی در مورد یک موضوع خاص کمک و یا نتایج انتخابات را پیش‌بینی کند. طبقه‌بندی و سازماندهی این حجم بسیار عظیم از نظرات در مورد یک موضوع خاص به‌صورت دستی کار آسانی نیست. از همین‌رو، نیاز به یک سیستم خودکار برای جمع‌آوری نظرات منجر به ظهور یک زمینه تحقیقاتی جدید به نام تحلیل احساسات شد. تحلیل احساسات زیرمجموعه از پردازش زبان طبیعی است [۱] [۲] که هدف اصلی آن استخراج خودکار احساساتی است که توسط افراد در یک متن بیان شده‌اند. تحلیل احساسات به طور کلی در سه سطح مورد تحقیق قرار می‌گیرد: سطح سند ، سطح جمله و سطح ویژگی. در تحلیل احساسات سطح سند و جمله فرض می‌شود که نظر بیان‌شده در تمام متن تنها به یک موضوع اشاره دارد. بدیهی است که این فرض در بسیاری از موارد منطقی نیست [۳]. در بسیاری از موارد، یک جمله می‌تواند به ویژگی‌های مختلفی و با قطبیت‌های متفاوت اشاره داشته باشد. بر اساس مثبت

بودن احساسات یک سند یا حتی یک جمله، نمی‌توان ارزیابی درستی از دیدگاه ارائه‌دهنده نظر در مورد تمام ویژگی‌های مورد بحثش داشت. در مقابل، تحلیل احساسات مبتنی‌بر ویژگی[۱] (ABSA) که همچنین تحلیل احساسات سطح ویژگی[۲] (ALSA) نامیده می‌شود، این امکان را می‌دهد تا دیدگاه صاحب نظر برای هر یک از ویژگی‌های موجودیت مورد اشاره در متن را شناسایی کنیم [۳] [۴] [۵]. تحلیل احساسات مبتنی‌بر ویژگی به‌طور کلی به چهار زیرمساله فرعی، دسته‌بندی و مورد پژوهش قرار می‌گیرد، که عبارتند از [۶] [۷] [۸]: استخراج واژه ویژگی[۳] (ATE)، قطبیت واژه ویژگی[۴] (ATP)، تشخیص مقوله ویژگی[۵] (ACD) و قطبیت مقوله ویژگی[۶] (ACP). در حالی‌که ATE سعی می‌کند تا واژه‌هایی که به یک ویژگی اشاره می‌کند را استخراج کند، ATP قطبیت هر واژه‌ی استخراج‌شده توسط مساله ATE را براساس مثبت، منفی و یا خنثی تعیین می‌کند. در طرف دیگر، ACD با توجه به مجموعه‌ای از مقوله‌های از پیش تعریف‌شده، قصد دارد تا زیرمجموعه‌ای از این مقوله‌ها را به یک نظر اختصاص دهد [۴] [۶] [۸] [۹] [۱۰] [۱۱] [۱۲] [۱۳] [۱۴] [۱۵]. آخرین زیرمساله از تحلیل احساسات مبتنی‌بر ویژگی یعنی ACP بر تعیین قطبیت هر مقوله شناسایی شده توسط مساله قبلی متمرکز است [۷] [۸]. در جدول ۱ تفاوت بین این چهار زیرمساله با یک مثال قابل مشاهده است.

جدول ۱. مقایسه بین چهار زیرمساله تحلیل احساسات مبتنی‌بر ویژگی

این گوشی هم خیلی جذابه هم باتری خیلی خوبی داره ولی هزینه خریدش خیلی زیاده.	
مساله	**خروجی**
استخراج واژه ویژگی	جذابه، باتری، هزینه خریدش
قطبیت واژه ویژگی	{جذابه: مثبت}، {باتری: مثبت}، {هزینه خریدش: منفی}
تشخیص مقوله ویژگی	طراحی، کارایی، قیمت
قطبیت مقوله ویژگی	{طراحی: مثبت}، {کارایی: مثبت}، {قیمت: منفی}

کارهای بسیار زیادی در زمینه تحلیل احساسات انجام شده است. با این وجود، به‌دلیل چندین چالش، کارهای بسیار محدودی در زمینه طبقه‌بندی ویژگی‌ها انجام گرفته است [۱۱]. از آن‌جایی که بیشتر مواقع در متن به مقوله‌های یک ویژگی به‌صورت صریح اشاره‌ای نمی‌شود، مساله تشخیص مقوله ویژگی در مقایسه با استخراج واژه ویژگی یک مساله چالش‌برانگیزتر است [۴] [۷] [۱۱]. در حالی‌که، واژه ویژگی به صراحت در جمله بیان می‌شوند، از همین‌رو این مساله در مقایسه با تشخیص مقوله ویژگی به مراتب ساده‌تر است [۱۵]. بیشتر پژوهش‌ها در زمینه تحلیل احساسات مبتنی‌بر ویژگی به شیوه‌ی نظارتی صورت گرفته‌اند. پژوهشگران معمولا ویژگی‌ها را استخراج و از الگوریتم‌های یادگیری ماشین برای آموزش مدل استفاده می‌کنند. این روش‌ها بر محور استخراج ویژگی‌ها به‌صورت دستی استوار هستند. حال آن‌که، چنین روش‌هایی نیاز به مهندسی ویژگی‌ها و یا منابع زبانی گسترده دارد. طی سال‌های اخیر، شبکه‌های عصبی عمیق که به عنوان یادگیری عمیق شناخته می‌شوند، در مسائل مختلف پردازش زبان طبیعی همانند، طبقه‌بندی متن، خلاصه‌سازی متن، سیستم‌های پرسش و پاسخ و بسیاری دیگر عملکرد بسیار قابل توجهی از خود نشان داده‌اند. مزیت مهم این روش‌ها، توانایی استخراج خودکار ویژگی‌ها با یادگیری از داده‌ها آموزشی است [۱۶]. همین امر، پژوهشگران را از فرآیند زمان‌بر و پیچیده مهندسی ویژگی‌ها بی‌نیاز می‌سازد. شبکه‌های عصبی حافظه طولانی کوتاه-مدت و کانولوشنی دو شبکه پرکاربرد در این زمینه هستند. در بیش‌تر روش‌های قبلی، دو زیرمساله ACD و ACP را به‌صورت دو کار جداگانه در نظر می‌گیرند و تنها برروی یکی از آن‌ها تمرکز می‌کنند. با این حال، در یک متن دارای نظر، نه تنها باید ویژگی‌ها، بلکه باید قطبیت آن‌ها نیز شناسایی شود. روش‌های خط لوله‌ای ابتدا ویژگی‌ها را شناسایی و سپس به شناسایی قطبیت می‌پردازند. چنین روش‌هایی کابردهای عملی را برآورده نمی‌کند. چرا که می‌تواند منجر به خطا در مدل گردد. یعنی

[۱] Aspect-Based Sentiment Analysis
[۲] Aspect-Level Sentiment Analysis
[۳] Aspect Term Extraction
[۴] Aspect Term Polarity
[۵] Aspect Category Detection
[۶] Aspect Category Polarity

خطاهای ACD به ACP انتقال پیدا کند. با توجه به اهمیت تحلیل احساسات مبتنی‌بر ویژگی و به‌خصوص دو زیرمساله آن یعنی ACD و ACP این مقاله متمرکز بر آن‌ها می‌باشد. همچنین، از آن‌جایی که در بیش‌تر کارهای گذشته به حل این دو زیرمساله به‌صورت جداگانه می‌پردازند، این پژوهش یک استراتژی جدید با استفاده از یادگیری چندوظیفه‌ای مبتنی‌بر شبکه‌های عمیق را برای تحلیل احساسات مبتنی‌بر ویژگی در نظرات فارسی با توجه به دو زیرمساله ACD وACP ارائه می‌دهد که می‌تواند آن‌ها را به‌صورت هم‌زمان حل نماید. در راستای این کار، مدل‌های مختلف مبتنی‌بر یادگیری عمیق در جهت بررسی و انتخاب بهترین ساختار استفاده شد. روش پیشنهادی با استفاده از یک مجموعه داده منحصربه‌فرد از نظرات ارائه شده در خصوص فیلم‌های فارسی مورد ارزیابی قرار گرفت. در ادامه، پس از بررسی کارهای مرتبط در این خصوص، جزئیات روش پیشنهادی و نتایج ارزیابی را شرح می‌دهیم.

۲. پیشینه

۱.۲. یادگیری عمیق

پیشرفت‌های اخیر در فن‌آوری شبکه‌های عصبی مصنوعی، به خصوص یادگیری عمیق، به‌شدت حوزه پردازش زبان طبیعی را تحت تاثیر قرار داده است. در بسیاری از زمینه‌های پردازش زبان طبیعی، استفاده از یادگیری عمیق سبب شده است نتایج از آنچه که در گذشته توسط روش‌های یادگیری ماشین و روش‌های آماری مورد استفاده قرار می‌گرفته است، فراتر رود [۱۷]. در روش‌هی یادگیری ماشین سنتی، ویژگی‌ها به‌صورت دستی و با مهندسی ویژگی‌ها استخراج می‌شدند که این امر نیاز به دانش زمینه‌ای داشته و هم‌چنین فرآیندی زمان‌بر و پرهزینه است. یادگیری عمیق که خود زیرمجموعه‌ای از روش‌های یادگیری ماشین است، به‌عنوان یادگیری بازنمایی یا یادگیری ویژگی‌ها شناخته می‌شود. یادگیری بازنمایی، تکنیکی است که ماشین را قادر می‌سازد تا ویژگی‌ها را از داده‌های خام به‌صورت خودکار بدون دخالت انسانی کشف کند. این توانایی مهم شبکه‌های عمیق که آن‌ها را از سایر روش‌های یادگیری ماشین سنتی برتر ساخته است، توسط تعداد لایه‌های زیادی که در ساختارش وجود دارد امکان‌پذیر می‌شود. همین توانایی استخراج خودکار توسط شبکه‌های عمیق، به‌سرعت آن‌ها را محبوب و جایگزین روش‌های سنتی یادگیری ماشین قرار داد. در ادامه این بخش، مروری کوتاه به برخی از معماری‌های شبکه‌های عمیق که در پردازش زبان طبیعی مورد استفاده قرار می‌گیرند، خواهیم داشت.

۱.۱.۲. شبکه عصبی کانولوشنی (CNN)

شبکه عصبی کانولوشنی یا به اختصار CNN یک زیرگروه از شبکه‌های عصبی است که ساختاری مشبک مانند دارد و متشکل از چندین لایه کانولوشنی و ادغام است که به دنبال آن‌ها یک یا چند لایه متصل کامل وجود دارد و از الگوهای تکرار شده در مجموعه داده استفاده می‌کند [۱۸] [۱۹]. هر چند به‌دلیل وجود الگوهای تکراری در تصاویر، CNN در بینایی رایانه رایج است. با این حال، آن‌ها همچنین در پردازش زبان طبیعی کاربرد دارند. چرا که، الگوهای تکراری نیز در متن ظاهر می‌شوند. شکل ۱ مدلی از یک معماری شبکه عصبی کانولوشنی برای طبقه‌بندی متن (احساسات) را نشان می‌دهد.

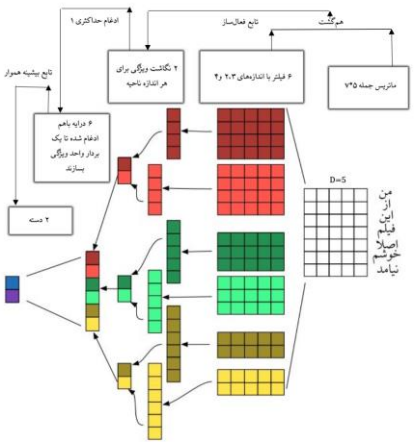

شکل ۱. نحوه کار شبکه CNN در ورودی متنی [۲۰]

در پردازش زبان طبیعی، به‌جای پیکسل‌های تصویر، ورودی متنی است که به صورت یک ماتریس (مجموعه جملات) نشان داده می‌شود. هر سطر از ماتریس با مجموعه‌ای از بردارهای کلمه مطابقت دارد. جز اصلی در CNN یک فیلتر کانولوشنی است. فیلترها ماتریس‌های کوچکی از وزن‌ها هستند. پهنای فیلترهای مورد استفاده در این زمینه عبارتنداز: سه، پنج و یا هفت. به این معنا که هر فیلتر بر روی سه، پنج یا هفت کلمه در امتداد جمله قرار می‌گیرد. این فیلترها روی سطرها در متن (جملات) حرکات می‌کنند و ضرب داخلی بین وزن و کلمات را انجام می‌دهند. تفاوت اصلی بین CNN در بینایی رایانه و پردازش زبان طبیعی این است که، فیلترها در بینایی رایانه معمولا دو بعدی هستند (با عرض و ارتفاع) و فیلترهای CNN در پردازش زبان طبیعی معمولا یک بعدی (فقط عرض) هستند. این از آن‌جایی ناشی می‌شود که الگوهای تکرار شونده در متن، خطوط هستند و الگوهای تکرار شونده در تصاویر دو بعدی هستند [۱۸].

۲.۱.۲. شبکه عصبی حافظه طولانی کوتاه-مدت (LSTM)

در سناریوهای دنیای واقعی، اطلاعات معنایی یک واژه اغلب به معنای مرتبط با واژه‌های قبلی در یک متن بستگی دارد. CNN نمی‌تواند این وابستگی را پردازش کند. چرا که آن‌ها هر کلمه را به طور مستقل در متن در نظر می‌گیرند [۲۱]. شبکه‌های عصبی بازگشتی یا به اختصار RNN برای کار با داده‌های متوالی طراحی شده‌اند که می‌تواند جایگزین مناسبی برای کارهایی که وابستگی بین واژه‌ها مهم است مورد استفاده قرار گیرد. سلول های عصبی درRNNها همانند یک زنجیر بهم متصل می‌شوند و هر کدام پیامی را به جانشین خود می‌رسانند که این انتقال متوالی اطلاعات سبب ایجاد یک نوع "حافظه" می‌شود [۱۸] [۲۲]. با این حال این شبکه‌ها توانایی حفظ وابستگی‌های بلند مدت را به‌دلیل مشکل محو گرادیان ندارند. از همین‌رو، نوع جدیدی از شبکه‌های عصبی برای وابستگی‌های بلند مدت به نام شبکه حافظه طولانی کوتاه مدت یا به اختصار LSTM ارائه گردید. این توانایی در LSTMها توسط مولفه‌های مهمی به نام سلول حالت و دروازه‌ها سبب می‌شود تا LSTM بتواند وابستگی‌های بلند مدت را حفظ و یک معماری مبتنی‌بر حافظه را ایجاد کند. شکل ۲ نمایی از ساختار درونی یک شبکه LSTM را نشان می‌دهد.

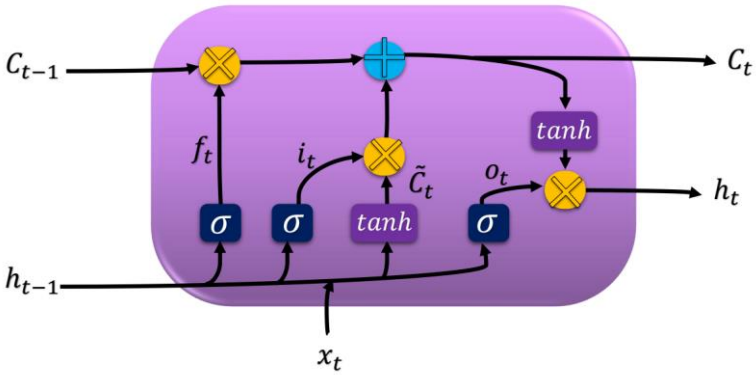

شکل ۲. معماری شبکه LSTM

۳.۱.۲. شبکه عصبی حافظه طولانی کوتاه-مدت دوطرفه (Bi-LSTM)

در راستای بهبود عملکرد شبکه‌های عصبی، شبکه‌های عصبی دوطرفه ساخته شدند. در یک LSTM دوطرفه (Bi-LSTM) آموزش شبکه با استفاده از دو LSTM انجام می‌شود. اولین شبکه توالی ورودی ارائه شده را می‌آموزد، در حالی‌که شبکه دیگر با توالی ورودی معکوس تغذیه می‌شود. از آن‌جایی که در انتها دو مدل آموزش دیده وجود دارد، خروجی هر دو شبکه با یک‌دیگر الحاق می‌شوند تا خروجی نهایی را بسازند.

۴.۱.۲. شبکه عصبی واحد بازگشتی دروازه‌دار (GRU)

تلاش برای ساده‌سازی LSTM منجر گردید تا نوع دیگری از شبکه‌های عصبی بازگشتی به نام واحد بازگشتی دروازه‌دار یا به اختصار GRU معرفی گردد. GRU در راستای حل مشکل محو گرادیان در RNN در مقایسه با LSTM که دارای سه دروازه می‌باشد، از دو

دروازه به نام‌های دروازه بروزرسانی و بازنشانی استفاده می‌کند. این دو دروازه تصمیم می‌گیرند که چه اطلاعاتی باید در خروجی به نمایش گذاشته شوند. شکل ۳ نمایی از ساختار درونی یک شبکه GRU را نشان می‌دهد.

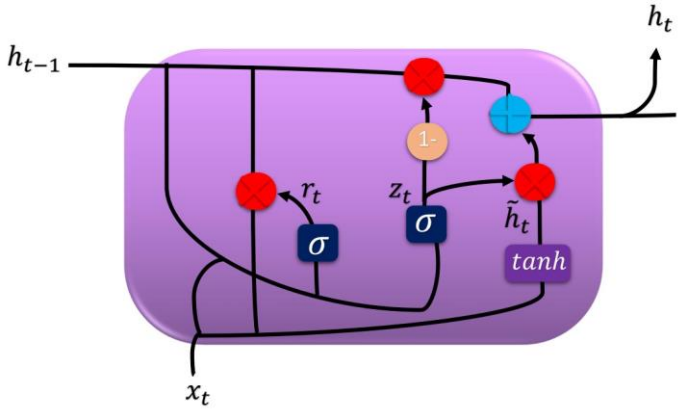

شکل ۳. معماری شبکه GRU

۲.۲. تعبیه‌سازی کلمات

تعبیه‌سازی کلمات، نمایشی از بردارهای حقیقی نگاشت شده به کلمات است. این بردارهای عددی در مقایسه با رویکردهای آماری در پردازش زبان طبیعی برای تبدیل کلمات به اعداد، ابعاد کم‌تری دارند. هم‌چنین، این بردارهای عددی اگر به خوبی آموزش دیده شده باشند، توانایی این را دارند که ارتباطات معنایی و نحوی بین کلمات را نشان دهند. تعبیه‌سازی کلمات، سنگ بنای بسیاری از کارهای انجام گرفته در حوزه پردازش زبان طبیعی است که از یادگیری عمیق استفاده می‌کنند. تعبیه‌سازی کلمات را می‌توان به دو رویکرد کلی بدست آورد. رویکرد اول، به‌صورت هم‌زمان با کاری اصلی توسط ساختار شبکه یاد گرفته شود. رویکرد دوم استفاده از تعبیه‌سازهای از پیش‌آموزش دیده است که قبلا توسط الگوریتم‌های یادگیری ماشین آموزش داده شده است.

۳.۲. یادگیری چندوظیفه‌ای

روش‌های سنتی یادگیری ماشین بهینه‌سازی برای یک معیار خاص برای انجام یک کار واحد است. برای تحقق این هدف، یک مدل با تنظیم دقیق ابرپارامترها آموزش داده می‌شود. هرچند با آموزش مدل می‌توانیم نتیجه رضایت‌بخشی را به‌دست آوریم، اما برخی از اطلاعاتی که به بهبود عملکرد مدل کمک می‌کنند، نادیده گرفته می‌شوند. به‌عبارت‌دیگر، ما دانش حاصل از سیگنال‌های آموزشی مربوط به وظایف مرتبط را نادیده می‌گیریم. برای استفاده موثر از این اطلاعات، رویکرد جدیدی به نام یادگیری چندوظیفه‌ای ارائه شد [۲۳] [۲۴] [۲۵] [۲۶]. یادگیری چندوظیفه‌ای با هدف یادگیری توام (مشترک) و هم‌زمان چندین کار مختلف و در عین حال مرتبط، در راستای به‌حداکثر رساندن کارآیی مدل انجام می‌شود. این کار با اشتراک‌گذاری اطلاعات در میان وظایف مختلف انجام می‌شود. هر وظیفه می‌تواند از وظایف دیگر بهره‌مند شود، در نتیجه کارآیی مدل افزایش می‌یابد. به‌طور کلی، هر زمان که یک مساله بهینه‌سازی را با بیش از یک تابع زیان آموزش می‌دهید، یا بخشی از تابع زیان شما از کار دیگری نشات می‌گیرد، در حال استفاده از یادگیری چندوظیفه‌ای هستید [۲۳] [۲۶] [۲۷] [۲۸]. در مسائل مرتبط با طبقه‌بندی، دو مفهوم وجود دارد که به‌راحتی اشتباه گرفته می‌شوند: طبقه‌بندی چند کلاسه که به معنای طبقه‌بندی با بیش از دو کلاس است و طبقه‌بندی چندبرچسبی که مجموعه‌ها از برچسب‌های هدف را با هر نمونه اختصاص می‌دهد. از آن‌جایی که هردوی آن‌ها پیشوند "چند" دارند، ممکن است به اشتباه این‌گونه تصور شود که هردو یادگیری چندوظیفه‌ای هستند. حال آن که این‌گونه نیست و هنگامی که صحبت از یادگیری چندوظیفه‌ای می‌شود به طبقه‌بندی چندبرچسبی اشاره می‌شود. اگر همه برچسب‌ها در وظیفه مورد نظر حالت دودویی داشته باشند، به آن طبقه‌بندی چندبرچسبی دودویی گویند [۲۷].

۱.۳.۲. یادگیری چندوظیفه‌ای عمیق

برای انجام یادگیری چندوظیفه‌ای با استفاده از یادگیری عمیق، از دو رویکرد کلی اشتراک‌گذاری پارامتر سخت و اشتراک‌گذاری پارامتر نرم استفاده می‌شود. اشتراک‌گذاری پارامترهای سخت رایج‌ترین روش در یادگیری عمیق چندوظیفه‌ای است. در این روش لایه‌های پنهان

در بین همه وظیفه‌ها به اشتراک گذاشته می‌شود، در حالی‌که چندین لایه خروجی مخصوص هر وظیفه وجود دارد. به این ترتیب، پارامترهای موجود در لایه پنهان مشترک، به اجبار به همه وظایف تعمیم داده می‌شود. این امر سبب می‌شود تا ریسک بیش‌برازش پایین‌تری برای هر وظیفه خاص داشته باشیم. به‌عبارت دیگر، هرچه وظایف بیشتری به‌طور توام آموزش داده شوند، مدل ما مجبور است بازنمایی پیدا کند که همه وظایف را به تصویر بکشد و وقوع بیش‌برازش را در وظیفه اصلی کم‌تر کند. در طرف دیگر، در اشتراک‌گذاری پارامتر نرم، هر وظیفه مدل خاص خود با پارامترهای مخصوص به خود را دارد. به عبارت دیگر، در اشتراک‌گذاری پارامتر نرم، هر مدل دارای مجموعه‌ای از وزن و بایاس مخصوص به خود است، در حالی‌که فاصله بین این پارامترها در مدل‌های مختلف منظم‌سازی می‌شود تا پارامترها مشابه شوند [۲۳] [۲۴] [۲۶] [۲۷]. در شکل ۴ ساختارهای این دو روش قابل مشاهده است.

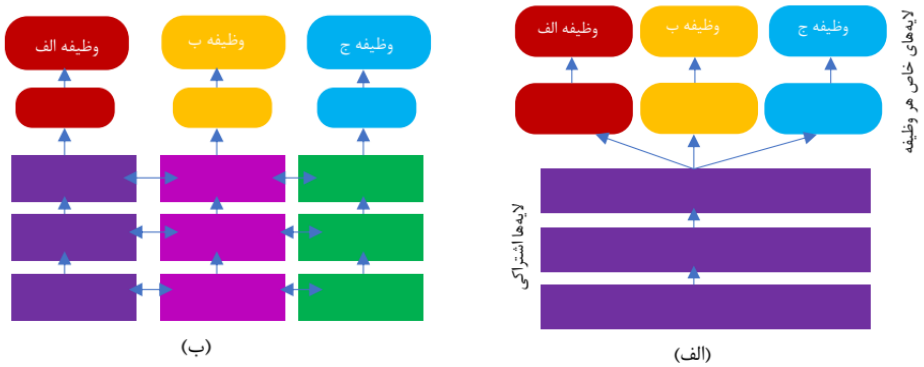

شکل ۴. اشتراک‌گذاری پارامتر سخت (الف) و اشتراک‌گذاری پارامتر نرم (ب) [۲۴].

۳. کارهای مرتبط

در این بخش ما کارهای مرتبط در زمینه تحلیل احساسات مبتنی‌بر ویژگی را بر اساس دو زیرمساله تشخیص مقوله ویژگی و قطبیت مقوله ویژگی تقسیم‌بندی کرده و به مرور آن‌ها می‌پردازیم.

۱.۳. تشخیص مقوله ویژگی

در اکثر کارهای گذشته در تشخیص مقوله ویژگی، به این مساله از دید یک مساله نظارتی (طبقه‌بندی) نگاه کرده‌اند و از الگوریتم‌های یادگیری ماشین و یادگیری عمیق استفاده کرده‌اند. پژوهش‌هایی نیز از دیدگاه یادگیری غیرنظارتی صورت گرفته است. کومار و همکارنش [۱۱] در سال ۲۰۲۰ با استفاده از رویکرد مبتنی‌بر قواعد انجمنی به تشخیص مقوله ویژگی‌ها پرداختند. در راستای این کار، برای مقابله با محدودیت‌های این قوانین آماری، یک رویکرد مبتنی‌بر قواعد ترکیبی را پیشنهاد کردند که متشکل از قواعد انجمنی و قواعد معنایی است. برای قواعد معنایی از جاساز کلمات استفاده کردند. در پایان به این نتیجه رسیدن که افزودن این قواعد اضافی و ترکیب آن، دقت طبقه‌بند را افزایش می‌دهد. قادری و همکارانش [۹] در سال ۲۰۱۹ مدلی نظارتی با عنوان LICD ارائه کردند که بر پایه تطبیق متن بدون استفاده از ابزار خاص یا استخراج ویژگی‌های دستی به تشخیص مقوله ویژگی‌ها می‌پردازد. برای این کار، آن‌ها مدل خود را با دو فرض توسعه دادند. فرض اول، در صورتی که شباهت معنایی بالایی بین جمله و مجموعه‌ای از کلمات نماینده آن مقوله وجود داشته باشد، باید به یک مقوله اختصاص داده شود. و دوم این‌که، یک جمله متعلق به یک مقوله خواهد بود اگر جملات شباهت معنایی و ساختاری به جمله‌ی مرتبط با یک مقوله داشته باشند. برای اعمال فرضیه‌ها، از فاصله کسینوسی نرم و برای مورد دوم، از فاصله واژه‌ساز استفاده کردند. موحدی و همکارنش [۱۳] در سال ۲۰۱۹ یک مدل یادگیری عمیق برپایه مکانیزم توجه ارائه دادند که می‌تواند با تمرکز بر قسمت‌های مختلف یک جمله، مقوله‌های مختلف را شناسایی کند.

۲.۳. قطبیت مقوله ویژگی

این مساله که تاکید بر انتساب قطبیت به هر یک از مقوله‌های ویژگی دارد، بر این فرض استوار است که مقوله‌ها پیش‌تر توسط یک گام جداگانه شناسایی شده‌اند. در بیشتر کارهای گذشته برای حل این مساله همانند مساله قبلی، با رویکردی نظارتی با آن برخورد کرده‌اند. زو

و همکارانش [۱۲] در سال ۲۰۱۸ به ارائه مدلی مبتنی‌بر شبکه عصبی پیچشی و مکانیزم دروازه‌ای پرداختند که این مدل در مقایسه با LSTM عملکرد بهتری را به‌همراه داشت. ایده اصلی این روش، استفاده از واحدهای دروازه‌ای Tanh-ReLU است که بسته به ویژگی و موجودیت می‌تواند به‌صورت انتخابی خروجی قطبیت را تولید کند. رودر و همکارانش [۲۹] در سال ۲۰۱۶ یک مدل سلسله‌مراتبی برای تحلیل احساسات مبتنی‌بر ویژگی ارائه دادند. آن‌ها نشان دادند که با اجازه دادن به مدل برای در نظر گرفتن ساختار و زمینه نظر، می‌توان از مدل‌هایی که تنها به اطلاعات جمله تکیه می‌کنند، پیشی گرفت و عملکرد بهتری ارائه داد و در مقایسه با مدل‌هایی که از منابع خارجی بزرگ استفاده می‌کنند، عملکردی رقابتی دارد. فو و همکارانش [۳۰] در سال ۲۰۱۹ در راستای حل مشکلات مربوط رویکردهای نظارتی که نیاز به داده‌های برچسب‌خورده دارند، یک رویکرد نیمه‌نظارتی براساس خودرمزنگار تغییرپذیر و مکانیزم توجه ارائه داد. علاوه‌بر این، آن‌ها به این نتیجه رسیدن که یک بردار واحد برای کلمات کارآیی کمی دارد، از همین‌رو برای یادگیری بهتر یک کلمه، بردار احساسی هر کلمه را به‌همراه آن به ورودی اضافه کردند. نتایج آن‌ها نشان داد که مدل‌ها آن‌ها قادر است احساسات دقیق‌تری را برای ویژگی داده شده به‌دست آورد. با این حال، مدل آن‌ها پیش‌بینی درستی را برای متون خاصی که کلمات احساسی قیاسی و متون طولانی بدون کلمات احساسی ندارند، ارائه نمی‌دهد.

۴. روش پیشنهادی

در این بخش، ابتدا دو مساله تشخیص مقوله ویژگی و قطبیت مقوله ویژگی را تعریف می‌کنیم و سپس، روش پیشنهای خود را برای تشخیص مقوله ویژگی و قطبیت مقوله ویژگی که می‌تواند به‌صورت توام صورت گیرد را ارائه می‌دهیم.

۱.۴. تعریف مساله

۱.۱.۴. تشخیص مقوله ویژگی

با فرض داشتن فهرستی از مقوله‌های از پیش تعریف‌شده (برای مثال در تحلیل احساسات فیلم‌های سینمایی، مقوله‌هایی همانند، بازیگر، کارگردان، موضوع و غیره)، هدف نگاشت زیرمجموعه‌ای از این مقوله‌ها به یک متن (نمونه) است. از آن‌جایی که هر متن می‌تواند مجموعه‌ای از مقوله‌ها را شامل شود، این مساله متناظر با یک مساله طبقه‌بندی چندبرچسبی است.

۲.۱.۴. قطبیت مقوله ویژگی

با فرض این‌که مجموعه‌ای از مقوله‌ها برای یک متن شناسایی شده باشد، هدف انتساب یکی از قطبیت‌های مثبت و یا منفی به هر یک از آن‌ها می‌باشد.

۳.۱.۴. تشخیص مقوله ویژگی و قطبیت مقوله ویژگی به‌صورت توام

روش پیشنهادی با تغییر در برچسب‌گذاری داده‌ها یا به عبارت دیگر، اضافه کردن یک کلاس خنثی، این توانایی را به مدل می‌دهد تا به‌صورت توام، دو زیرمساله تشخیص مقوله ویژگی و قطبیت مقوله ویژگی، با استفاده از یادگیری عمیق چندوظیفه‌ای قابل حل شود. برای این کار، کلاس‌های مقوله ویژگی را تغییری نداده و تنها یک کلاس خنثی به کلاس‌های قطبیت ویژگی اضافه می‌کنیم. براین اساس، هر کلاسی از مقوله ویژگی، خود دارای سه کلاس مثبت، منفی و خنثی می‌شود. خنثی در این‌جا به معنای این خواهد بود که نظر ارائه شده عضو این کلاس نیست. دلیل اضافه شدن این کلاس خنثی این است که، نمی‌توان تنها با داشتن دو کلاس قطبیت مثبت و منفی در مورد طبقه‌بندی نهایی قضاوت کرد. به‌طور دقیق‌تر، از آن‌جایی که این مساله متناظر با طبقه‌بندی چندبرچسبی است و این امکان وجود دارد که هر نمونه عضو یک یا چند مورد از این‌ها کلاس‌ها باشد یا نباشد، پس کلاس سومی را ایجاد می‌کنیم تا اگر نمونه متعلق به آن کلاس نبود، طبقه‌بند مروبط به آن کلاس بتواند آن را تشخیص دهد. با فرض نبودن این کلاس خنثی، باید برای هر یکی از مقوله‌های ویژگی (یا همان کلاس‌های بازیگر، کارگردان و غیره) احتمال مثبت و یا منفی بودن را در نظر گرفت. یعنی، یک نظر حتما باید این مقوله ویژگی (دسته) را داشته باشد؛ به‌صورت مثبت و یا منفی. مشاهده می‌شود که این کار ایده درستی نیست و مدل توانایی تشخیص ندارد. با افزودن این کلاس خنثی، برای مدل ممکن می‌شود تا اگر نظری عضو آن کلاس باشد یا نباشد، آن را تشخیص و قطبیت آن را هم شناسایی کند. در شکل ۵ مثالی از نحوه برچسب‌گذاری با استفاده از این روش برای درک بهتر مشاهده می‌شود.

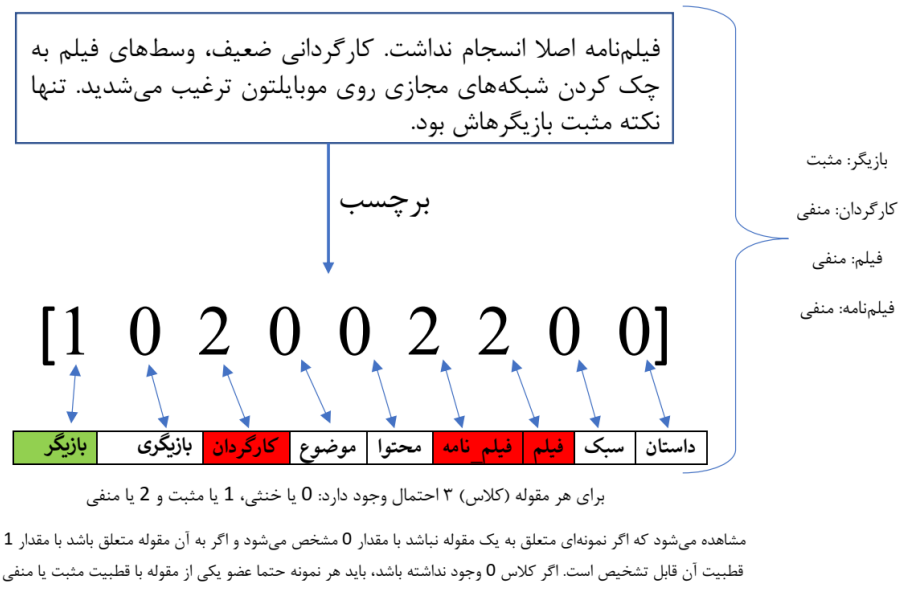

شکل ۵. مثالی از برچسب‌گذاری در روش پیشنهادی

۲.۴. معماری کلی برای روش پیشنهادی

در طراحی مدل برای این روش پیشنهادی، در لایه خروجی مدل باید حتما از تابع بیشنه‌هموار (SoftMax) استفاده کرد. چرا که هر دسته‌ای از مقوله‌ها خود داری ۳ کلاس متفاوت است. از آن‌جایی که تعداد مقوله‌های ما ۹ می‌باشد، از ۹ تابع بیشینه‌هموار با ۳ نرون استفاده شد. معماری کلی روش پیشنهادی براساس اشتراک‌گذاری پارامتر نرم برای حل دو زیرمساله تشخیص مقوله ویژگی و قطبیت مقوله ویژگی برای یادگیری توام، در شکل ۶ قابل مشاهده است. همان‌طور که مشاهده می‌شود، در لایه آخر این معماری به تعداد کلاس‌ها در مجموعه داده از تابع بیشینه‌هموار ۳ نرونی استفاده شده است.

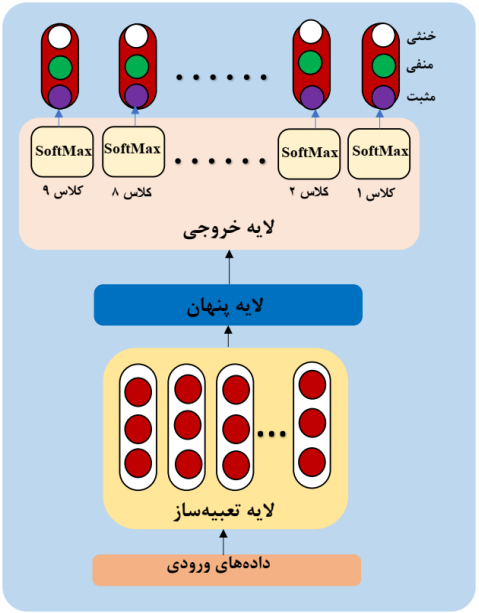

شکل ۶. معماری کلی روش پیشنهادی

۵. نتایج

۱.۵. مجموعه داده

هر سیستم یادگیری ماشین، در راستای یادگیری نیاز به یک مجموعه داده مناسب دارد. متاسفانه، در زبان فارسی مجموعه داده‌ی جامع و واحدی در زمینه‌ی تحلیل احساسات مبتنی‌بر ویژگی وجود ندارد. از همین‌رو، برای این پژوهش مجموعه داده‌هایی را از کابران رسانه‌های اجتماعی در حوزه‌ی فیلم‌های سینمایی از تارنمای سینماتیکت[۷] جمع‌آوری کرده و به‌صورت دستی اقدام به برچسب‌زنی آن‌ها کردیم. تعداد این داده‌ها برای مجموعه داده‌های آموزشی ۲۰۰۰ و برای مجموعه آزمایشی ۲۰۰ نمونه با ۹ کلاس در دو قطبیت مثبت و منفی است. توزیع داده‌ها در کلاس‌های مختلف در جدول ۲ قابل مشاهده است.

جدول ۲. توزیع داده‌های آموزشی و آزمایشی

کلاس/کلاس		بازیگر	بازیگری	داستان	سبک	فیلم	فیلم‌نامه	محتوا	موضوع	کارگردان
مثبت	داده‌های آموزشی	۱۵۲	۲۰۰	۶۱	۵۹	۹۰۷	۶۱	۳۸	۵۶	۷۷
	داده‌های آزمایشی	۱۱	۱۷	۵	۱۶	۸۵	۷	۷	۹	۷
منفی	داده‌های آموزشی	۶۷	۱۱۰	۷۲	۶۸	۸۳۱	۱۱۱	۱۰۹	۶۹	۶۲
	داده‌های آزمایشی	۶	۷	۷	۳	۶۱	۸	۱۴	۶	۵

۲.۵. معیارهای ارزیابی

از آن‌جایی که این مساله نوعی طبقه‌بندی چندبرچسبی می‌باشد، باید از معیارهای مناسبی جهت ارزیابی کارآیی مدل‌ها استفاده شود. این معیارها متفاوت از معیارهای طبقه‌بندی تک‌برچسبی هستند. در همین راستا، ما برای ارزیابی کارآیی مدل‌ها از ۳ معیار دقت زیرمجموعه، شاخص جاکارد (دقت چندبرچسبی) و خطای همینگ استفاده کرده‌ایم. در معیار دقت زیرمجموعه که یکی از سختگیرانه‌ترین معیارها است، باید مجموعه پیش‌بینی شده با مجموعه واقعی مساله کاملا یکسان باشد. معادله ۱ نحوه محاسبه آن را نشان می‌دهد.

$$subsetAccuracy(h) = \frac{1}{n}\sum_{i=1}^{n}[h(x_i) == Y_i] \quad (۱)$$

شاخص جاکارد که از آن به عنوان دقت چندبرچسبی نیز یاد می‌شود، به عنوان تعداد برچسب‌های پیش‌بینی شده درست، تقسیم بر اجتماع برچسب‌های واقعی تعریف می‌شود. معادله ۲ نحوه محاسبه این معیار ارزیابی را نشان می‌دهد.

$$jaccard\ index(h) = \frac{1}{n}\sum_{i=1}^{n}\frac{|h(x_i) \cap Y_i|}{|h(x_i) \cup Y_i|} \quad (۲)$$

خطای همینگ، تفاضل متقارن بین خروجی واقعی مساله در مقابل خروجی طبقه‌بند را محاسبه می‌کند. به عبارت دیگر، کسری از برچسب‌هایی که برای یک نمونه به درستی پیش‌بینی نشده است را نشان می‌دهد. معادله ۳ نحوه محاسبه این معیار را نشان می‌دهد.

$$hammingloss(h) = \frac{1}{n}\sum_{i=1}^{n}[h(x_i)\ XOR\ Y_i] \quad (۳)$$

[۷] https://cinematicket.org

در معادلات ۱ تا ۳، Y_i خروجی واقعی برای نمونه iام، $h(x_i)$ خروجی طبقه‌بند و n نمایان‌گر تعداد نمونه‌ها در مجموعه داده است.

۳.۵. مدل‌های پایه و ابرپارمترها

در این پژوهش ما از چهار مدل پایه یادگیری عمیق یعنی، CNN، LSTM، Bi-LSTM و GRU برای آموزش و سپس ارزیابی نتایج استفاده کرده‌ایم. مدل CNN مورد استفاده در این پژوهش شامل چندین مرحله است: در ابتدا با استفاده از کتابخانه Keras نسبت به تعبیه‌سازی کلمات اقدام شد. در مرحله بعد، عملگر کانولوشن برروی لایه تعبیه کلمات اعمال می‌شود که در این مرحله از ۲۵۶ فیلتر با اندازه ۳ استفاده شد تا ویژگی‌های نهایی نمونه ورودی را تشکیل دهد. در نهایت یک لایه متصل کامل قرار داده شد تا براساس کلاس‌های موجود طبقه‌بندی را انجام دهد. همانند شبکه CNN، سه مدل دیگر از چندین مرحله تشکیل شده‌اند. در مرحله اول از تعبیه‌سازی کلمات برای تبدیل کلمات به بردارهای عددی استفاده شد. سپس این بردارها به بلوک‌های این شبکه‌ها داده شد تا اطلاعات متنی را استخراج کنند. در نهایت، از یک شبکه متصل کامل استفاده شد تا یک نگاشت بین ویژگی‌های استخراج‌شده توسط این مدل‌ها به مجموعه کلاس‌های موجود، ایجاد کند. هم‌چنین، در تمامی معماری مدل‌ها از حذف تصادفی برای جلوگیری از بیش‌برازش استفاده شده است. در جدول ۳ فهرست ابرپارمترهای مورد استفاده در این پژوهش قابل مشاهده است.

جدول ۳. فهرست ابرپارمترهای مدل‌ها

ابرپارمتر	مقدار
اندازه ابعاد تعبیه‌ساز	۳۰۰
حذف تصادفی	۰.۵
دوره	۲۰
اندازه دسته	۲۵۶

۴.۵. نتایج آزمایش‌ها با مدل‌های مختلف برروی مجموعه داده

جدول ۴ مقایسه مدل‌ها را براساس سه معیار دقت زیرمجموعه، شاخص جاکارد و خطای همینگ نشان می‌دهد. همان‌طور که مشاهده می‌شود، مدل CNN در معیار دقت زیرمجموعه با امتیاز ۶۷.۵ درصد و شاخص جاکارد با امتیاز ۷۷.۰۷۵ درصد توانسته است بهترین کارآیی را در بین سایر مدل‌ها از خود نشان دهد. با این حال، در معیار خطای همینگ در مقایسه با Bi-LSTM بدتر عمل کرده است. از آن‌جایی که معیار دقت زیرمجموعه یکی از سخت‌گیرانه‌ترین معیارها در طبقه‌بندی چندبرچسبی می‌باشد، می‌توان گفت CNN بهترین کارآیی را در این مساله و مجموعه داده داشته است. نکته قابل توجه، برتری شبکه CNN بر شبکه‌های عصبی بازگشتی است. دلیل آن، کاکرد خوب CNN در استخراج ویژگی‌های محلی است. از آن‌جایی که احساسات در نظرات و متون با کلمات و عباراتی خاص بیان می‌شوند، CNN توانسته است این کلمات و عبارت را در این مجموعه داده بهتر شناسایی و تشخیص دهد و کارآیی بهتری از خود نشان دهد.

جدول ۴. نتایج آزمایش‌ها با مدل‌های مختلف برروی مجموعه داده آزمایشی

مدل/معیار	دقت زیرمجموعه↑	شاخص جاکارد↑	خطای همینگ↓
CNN	**٪۶۷.۵**	**٪۷۷.۰۷۵**	۰.۰۴۶
LSTM	٪۶۳	٪۷۳.۴۱۷	۰.۰۵۱
Bi-LSTM	٪۶۵	٪۷۵.۳۴۲	**۰.۰۴۴**
GRU	٪۶۳.۵	٪۷۵.۳۴۲	۰.۰۴۹

۶. نتیجه‌گیری

در این مقاله، به‌منظور یادگیری توام دو زیرمساله مهم تحلیل احساسات مبتنی‌بر جنبه یعنی، ACD وACP در زبان فارسی، از یک استراتژی ساده ولی کارآمد استفاده کردیم. در این راستا، از تغییر در نحوه برچسب‌گذاری داده‌ها یا عبارت دیگر افزودن یک کلاس خنثی استفاده شد تا مدل یادگیری عمیق چندوظیفه‌ای توانایی تشخیص مقوله و قطبیت آن را داشته باشد. در گام بعدی، چند مدل پایه یادگیری عمیق را در این خصوص آموزش داده و به مقایسه و ارزیابی نتایج آن پرداختیم که در پایان، مدل CNN به دلیل توانایی بالا در استخراج ویژگی‌های محلی توانست در مقابل سایر مدل‌ها در مجموعه داده این پژوهش کارآیی بهتری از خود نشان دهد.

منابع

[۱] Nazir A, Rao Y, Wu L, Sun L, ۲۰۲۰. Issues and Challenges of Aspect-based Sentiment Analysis: A Comprehensive Survey. IEEE Transactions on Affective Computing.
[۲] Capuano N, Greco L, Ritrovato P, Vento M, ۲۰۲۰. Sentiment analysis for customer relationship management: an incremental learning approach. Applied Intelligence.
[۳] Zhou J, Huang JX, Chen Q, Hu QV, Wang T, He L, ۲۰۱۹. Deep Learning for Aspect-Level Sentiment Classification: Survey, Vision, and Challenges. IEEE Access.
[٤] Zhu P, Chen Z, Zheng H, Qian T, ۲۰۱۹. Aspect Aware Learning for Aspect Category Sentiment Analysis. ACM Transactions on Knowledge Discovery from Data.
[٥] V H, Al E, ۲۰۲۱. Ensemble Models for Aspect Category Related ABSA Subtasks. Turkish Journal of Computer and Mathematics Education.
[٦] Brychcín T, Konkol M, Steinberger J, ۲۰۱٤. UWB: Machine Learning Approach to Aspect-Based Sentiment Analysis. Proceedings of the ۸th International Workshop on Semantic Evaluation.
[۷] Laskari N, Sanampudi S, ۲۰۱٦. Aspect Based Sentiment Analysis Survey.
[۸] Pathak AR, Agarwal B, Pandey M, Rautaray S, ۲۰۲۰. Application of Deep Learning Approaches for Sentiment Analysis. Algorithms for Intelligent Systems.
[۹] Ghadery E, Movahedi S, Jalili Sabet M, Faili H, Shakery A, ۲۰۱۹. LICD: A Language-Independent Approach for Aspect Category Detection. Lecture Notes in Computer Science.
[۱۰] Dilawar N, Majeed H, Beg MO, Ejaz N, Muhammad K, Mehmood I, et al, ۲۰۱۸. Understanding Citizen Issues through Reviews: A Step towards Data Informed Planning in Smart Cities. Applied Sciences.
[۱۱] Kumar A, Saini M, Sharan A, ۲۰۲۰. Aspect category detection using statistical and semantic association. Computational Intelligence.
[۱۲] Xue W, Li T, ۲۰۱۸. Aspect Based Sentiment Analysis with Gated Convolutional Networks. Proceedings of the ٥٦th Annual Meeting of the Association for Computational Linguistics.
[۱۳] Movahedi S, Ghadery E, Faili H, Shakery A, ۲۰۱۹. Aspect Category Detection via Topic-Attention Network.
[۱٤] babu my, reddy pvp, bindu cs, ۲۰۲۰. aspect category polarity detection using multi class support vector machine with lexicons based features and vector based features.
[۱٥] Li Y, Yin C, Zhong S, ۲۰۲۱. Sentence Constituent-Aware Aspect-Category Sentiment Analysis with Graph Attention Networks.
[۱٦] Zhu P, Qian T, ۲۰۱۸. Enhanced Aspect Level Sentiment Classification with Auxiliary Memory.
[۱۷] Otter DW, Medina JR, Kalita JK, ۲۰۱۹. A Survey of the Usages of Deep Learning in Natural Language Processing.
[۱۸] Sorin V, Barash Y, Konen E, Klang E, ۲۰۲۰. Deep Learning for Natural Language Processing in Radiology—Fundamentals and a Systematic Review. Journal of the American College of Radiology.
[۱۹] HARSHA KADAM S, ۲۰۲۰. Text analysis for email multi label classification, MSc Thesis, university of gothenburg.

[۲۰] Liland Bjormyr T, ۲۰۱٦. Deep Learning with emphasis on extracting information from text data, MSc Thesis, Norwegian University of Science and Technology.
[۲۱] Behera RK, Jena M, Rath SK, Misra S, ۲۰۲۱. Co-LSTM: Convolutional LSTM model for sentiment analysis in social big data. Information Processing & Management.
[۲۲] Rodríguez Medina S, ۲۰۱۹. Multi-Label Text Classification with Transfer Learning for Policy Documents, MSc Thesis, Uppsala University.
[۲۳] Wang S, Wang Q, Gong M, ۲۰۲۰. Multi-Task Learning Based Network Embedding. Frontiers in Neuroscience.
[۲٤] Ruder S, ۲۰۱۷. An Overview of Multi-Task Learning in Deep Neural Networks.
[۲٥] Vithayathil Varghese N, Mahmoud QH, ۲۰۲۰. A Survey of Multi-Task Deep Reinforcement Learning. Electronics.
[۲٦] Ruder S, ۲۰۱۹. Neural Transfer Learning for Natural Language Processing, PhD Thesis, NATIONAL UNIVERSITY OF IRELAND.
[۲۷] Xin W, ۲۰۲۰. Multi-Task Deep Learning for Affective Content Detection from Text, MSc Thesis, University of Ottawa.
[۲۸] Gong T, Lee T, Stephenson C, Renduchintala V, Padhy S, Ndirango A, et al, ۲۰۱۹. A Comparison of Loss Weighting Strategies for Multi task Learning in Deep Neural Networks. IEEE Access.
[۲۹] Ruder S, Ghaffari P, Breslin JG, ۲۰۱٦. A Hierarchical Model of Reviews for Aspect-based Sentiment Analysis.
[۳۰] Fu X, Wei Y, Xu F, Wang T, Lu Y, Li J, et al, ۲۰۱۹. Semi-supervised Aspect-level Sentiment Classification Model based on Variational Autoencoder. Knowledge-Based Systems.

View publication stats