Predicting mRNA degradation in the development of covid-19 vaccine using deep learning methods

Milad Vazan

پیش‌بینی ازهم‌پاشیدگی mRNA در توسعه واکسن کوید-۱۹ با استفاده از روش‌های یادگیری عمیق

میلاد وزان*
دانشگاه تبریز، گروه علوم کامپیوتر
*E-mail: m.vazan97@ms.tabrizu.ac.ir **

چکیده

نیاز فوری برای مبارزه و پیروزی در برابر همه‌گیری ویروس کوید-۱۹، و هم‌چنین مزایای زیاد واکسن‌های mRNA سبب شد تا محققان این واکسن‌ها را به عنوان کاندیدی در این خصوص قرار دهند و تمرکز بیشتری بر آن‌ها داشته باشند. با این حال، طراحی مولکول‌های mRNA پایدار، چالشی است که محققان با آن روبه‌رو هستند. در این مقاله ما با استفاده از یادگیری عمیق، چهار مدل مختلف، LSTM، Bi-LSTM، GRU و Bi-GRU را برای مجموعه داده OpenVaccine RNA که توسط دانشگاه استنفورد ارائه گردیده است تا براساس آن نرخ ازهم‌پاشیدگی احتمالی، برای هر موقعیت در داخل مولکول RNA را پیش‌بینی کند، طراحی کردیم. این پیش‌بینی‌ها می‌تواند در توسعه واکسن‌های mRNA بسیار مفید باشند. پس‌از ارزیابی مدل‌های طراحی‌شده، این نتیجه حاصل شد که شبکه‌های عصبی دوطرفه از آن‌جایی که اطلاعات گذشته و آینده را فراهم می‌کنند، میزان اطلاعات موجود را افزایش داده که نتیجه آن افزایش کارآیی مدل را به‌همراه دارد.

کلمات کلیدی: کوید-۱۹، بیوانفورماتیک، یادگیری عمیق، ازهم‌پاشیدگی آران‌ای پیام‌رسان

۱. مقدمه

واکسیناسیون یکی از بزرگترین دست‌آوردهای پزشکی مدرن و موفق‌ترین روش پزشکی برای پیش‌گیری و کنترل بیماری محسوب می‌شود. واکسن‌ها یک ابزار حیاتی در کاهش میزان عفونت‌ها و بیماری‌ها در سطح جهان هستند (Anand P, Stahel V, 2021). ریشه‌کنی آبله یکی از بهترین نمونه‌هایی است که نشان می‌دهد چگونه واکسیناسیون یک بیماری کشنده را متوقف و جان میلیون‌ها نفر را نجات داده است (Li y et al., 2021). در آینده، واکسن‌ها این پتانسیل را دارند که نه تنها در برابر بیماری‌های عفونی، بلکه برای سرطان به عنوان یک ابزار پیش‌گیرانه و درمانی و از بین بردن آلرژن‌ها مورد استفاده قرار گیرند (Zhang et al., 2019).

هرچند، توسعه واکسن‌های سنتی اغلب ۱۵سال یا بیشتر از مرحله طراحی اولیه تا مطالعات بالینی به طول می‌انجامد (Li y et al, 2021). با این حال، با همه‌گیری کووید-۱۹ و میلیون‌ها مبتلای عفونی و کشته در سراسر جهان، زندگی انسان‌ها به‌شدت تحت تاثیر این بیماری قرار گرفت. از همین‌رو، نیاز فوری برای توسعه واکسن ایجاد و مسابقه‌ای را در سراسر جهان برای تولید واکسن علیه این بیماری به‌وجود آورد. نتیجه آن، منجربه کاندید قرار دادن واکسن‌های mRNA گردید. چرا که دهه‌ها است محققان در حال مطالعه و کار با واکسن‌های mRNA هستند و این واکسن‌ها به دلیل مزایای زیادی که دارند، همانند فرآیند توسعه آسان، زمان کم برای توسعه و مهم‌تر و بزرگتر از همه، ایمنی و ماهیت غیر عفونی آن به‌دلیل تزریق مستقیم و ترجمه از RNA پیام‌رسان به پروتئین در بدن انسان، بهترین گزینه هستند (Qaid T et al., 2021).

با این حال، طراحی مولکول‌های mRNA پایدار، بزرگ‌ترین چالش در توسعه این واکسن‌ها می‌باشد (Asif Imran et al,. 2020). چرا که محققان دریافتند، مولکول‌های RNA تمایل به ازهم‌پاشیدگی خودبه‌خودی دارند. این یک محدودیت بسیار جدی است، چرا

که تنها یک برش می‌تواند واکسن mRNA را بی‌فایده کند. در شرایط عادی، این مولکول‌ها در عرض چند دقیقه تا چند ساعت به‌سرعت تخریب می‌شوند. واکسن‌های mRNA فقط تحت فریزر شدید یا نگهداری در دمای بسیار پایین پایدار می‌مانند. حمل و نقل یا تحویل واکسن‌ها از این طریق بسیار دشوار است. بدون یافتن راهی در جهت افزایش ماندگاری آن‌ها، حتی بهترین واکسن‌های مبتنی‌بر RNA به‌ویژه در کشورهای در حال توسعه که دسترسی مطمئنی به تهویه مطبوع یا برودت ندارند، کاربرد محدودی خواهد داشت. هنوز به‌طور دقیق مشخص نیست که کدام بخش از مولکول‌های RNA بیشتر مستعد ازهم‌پاشیدگی خودبه‌خود هستند. بنابراین، پیش‌بینی دقیق واکنش‌پذیری و ازهم‌پاشیدگی mRNA دشوار (Wayment-Steele et al., 2020) و آزمایش، یک فرآیند فوق‌العاده وقت‌گیر در تعیین این مقادیر است. در این راستا، مجموعه داده‌ای به نام OpenVaccine RNA توسط دانشگاه استنفورد در اختیار متخصصین علم داده قرار گرفته تا براساس آن به طراحی مدلی بپردازند که نرخ ازهم‌پاشیدگی احتمالی، برای هر موقعیت در داخل مولکول RNA را پیش‌بینی کند (Stanford University, 2020).

با توجه به اهمیت موضوع، پژوهش‌هایی در این خصوص صورت گرفته است. در پژوهش (Asif Imran et al,. 2020) با کمک مجموعه داده OpenVaccine RNA یک مدل شبکه عصبی بازگشتی توسعه یافته شد تا به محققین بیوانفورماتیک، در تشخیص این‌که در کجا ممکن است mRNA تحت برخی از اعمال، ناپایدار و مستعد ازهم‌پاشیدگی گردد، کمک کنند. در این راستا، یک مدل LSTM[1] منظم‌شده ارائه دادند و دریافتند که الگوریتم‌های بازگشتی از الگوریتم‌های مبتنی‌بر درخت در این مساله کارآیی بهتری دارد. پژوهش (Qaid T et al,. 2021) از مدل‌سازی LSTM و GRU[2] برای پیش‌بینی توالی‌های mRNA که مسبب ازهم‌پاشیدگی mRNA واکسن کوید-۱۹ هستند، استفاده کردند. این مدل‌ها با پیش‌بینی پنج مقدار واکنش‌پذیری برای هر موقعیت در توالی، ازهم‌پاشیدگی را پیش‌بینی می‌کنند. هم‌چنین، در این پژوهش از دو روش کدگذاری پایه و کدگذاری کدون استفاده کردند. علاوه‌براین، برای تعمیم‌دهی بهتر مدل، از تکنیک‌های افزودگی در جهت تولید داده‌های جدید استفاده تا مساله بیش‌برازش را کاهش دهد.

یادگیری عمیق طی سال‌های اخیر، به محرک اصلی راه‌حل‌های نوآورانه در حل مسائل پیچیده تبدیل گردیده است. تا قبل از پیدایش یادگیری عمیق، روش‌های سنتی یادگیری ماشین، بیش‌از حد به مهندسی ویژگی‌ها داده‌ها وابسته بودند. این روش‌ها نیاز به یک متخصص در دامنه موضوع داشت تا استخراج ویژگی‌ها را به‌صورت دستی انجام دهد. حال آن‌که، این استخراج ویژگی‌ها به صورت دستی فرآیندی پرهزینه و چالش‌انگیز است. پیدایش یادگیری عمیق توانست به سرعت جایگزین این روش‌های سنتی شود. چرا که این توانایی را دارد که به‌صورت خودکار متناسب با هر مساله استخراج ویژگی‌ها را انجام دهد (وزان م، ۱۳۹۹).

با توجه به کارکرد بسیار خوب و موفق یادگیری عمیق طی سال‌های اخیر در بسیاری از حوزه‌ها و هم‌چنین در حوزه بیوانفورماتیک، هدف اصلی این مقاله، برمحوریت استفاده از رویکرد یادگیری عمیق، در جهت پیش‌بینی ازهم‌پاشیدگی mRNA در توسعه واکسن کوید-۱۹می‌باشد. در همین راستا، برای حل این مساله ما از چهار مدل یادگیری عمیق که شامل شبکه‌های LSTM، Bi-LSTM[3]، GRU و Bi-GRU[4] می‌شود، استفاده کردیم تا نتایج آن‌ها را در پیش‌بینی ازهم‌پاشیدگی mRNA مورد ارزیابی و مقایسه قرار دهیم. این شبکه‌ها مناسب برای داده‌هایی هستند که حالت توالی (هر قطعه به نوعی رابطه‌ای با قطعات قبل و بعد از خود دارد) دارند. در ادامه مروری کوتاه بر آن‌ها خواهیم داشت.

شبکه‌ی عصبی حافظه طولانی کوتاه-مدت که به اختصار LSTM نامیده می‌شود، نوعی خاصی از شبکه‌های عصبی در جهت یادگیری وابستگی‌های بلند مدت است. وجود منطق دروازه‌دار، یک معماری مبتنی‌بر حافظه را در LSTM ممکن می‌سازد (وزان م، ۱۳۹۹). LSTM از سه دروازه ورودی، خروجی و فراموشی تشکیل شده است. دروازه ورودی، محافظت در برابر داده‌های نامرتبط را

[1] Long short-term memory
[2] Gated recurrent unit
[3] Bi-directional long short-term memory
[4] Bi-directional Gated Recurrent Unit

بر عهده دارد. دروازه فراموشی میزان فراموشی اطلاعات قبلی موجود در سلول حافظه را کنترل می‌کند (Zhou et al., 2019) و دروازه خروجی، در نمایش یا عدم نمایش محتویات درون سلول نقش دارد. هر سلول این دروازه‌ها به حالت مخفی قبلی و فعلی بستگی دارد. در راستای ساده‌سازی شبکه‌های LSTM نوع دیگری از شبکه‌ی بازگشتی به نام واحد بازگشتی دروازه‌دار که به اختصار GRU نامیده می‌شود، ارائه گردید. این شبکه‌ها در مقایسه با شبکه‌ی LSTM تنها از دو دروازه بروزرسانی و بازنشانی برای کنترل اطلاعات استفاده می‌کنند. وجود تعداد پارمتر کم‌تر در ساختار این شبکه، پیچیدگی محاسباتی آن را کم‌تر کرده است. با این حال، این شبکه در بیشتر کارها مشابه، یا بهتر از LSTM عمل می‌کند (وزان م، ۱۳۹۹). شکل ۱ ساختار شبکه‌های LSTM و GRU را نشان می‌دهد.

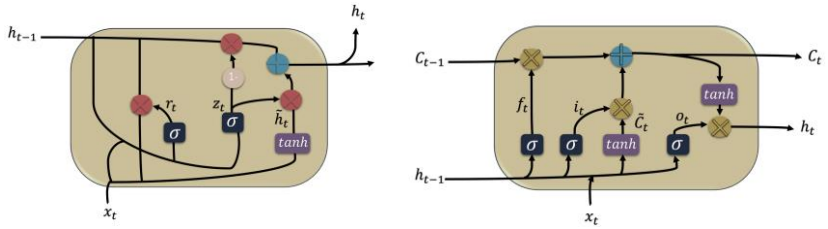

(ب) (آ)

شکل ۱. (آ) ساختار شبکه LSTM و (ب) ساختار شبکه GRU

در راستای افزایش کارآیی شبکه‌های عصبی، شبکه‌های عصبی دوطرفه همانند، شبکه‌های LSTM و GRU دوطرفه ساخته شدند. شبکه‌های دوطرفه هنگام آموزش از دو شبکه به‌طور هم‌زمان استفاده می‌کند که سبب می‌شود، هم اطلاعات گذشته و هم اطلاعات آینده از این طریق در دسترس باشند. یکی از این شبکه‌ها توالی ورودی را به همان صورتی که به شبکه تغذیه شده می‌آموزد، در حالی‌که شبکه دیگر، این توالی را به‌صورت معکوس ورودی می‌آموزد. این حالت تغذیه ورودی از دوطرف، میزان اطلاعات موجود را افزایش می‌دهد. در انتها، از آن‌جایی که دو شبکه در این ساختار وجود دارد، خروجی هر دو شبکه با یک‌دیگر ادغام می‌شود تا خروجی نهایی را به نمایش بگذارند (Munawar et al., 2021).

۲. مواد و روش‌ها

در این پژوهش از مجموعه داده OpenVaccine RNA (Stanford University, 2020) برای پیش‌بینی توالی‌های mRNA که مسبب ازهم‌پاشیدگی mRNA واکسن کوید-۱۹ هستند، استفاده شده است. مجموعه داده آموزشی شامل ۲۴۰۰ توالی RNA به طول ۱۰۷ می‌باشد. برای هر توالی RNA، اطلاعاتی همانند، توالی، ساختار و نوع حلقه پیش‌بینی‌شده، داده شده است. توالی ترکیبی از بازهای نیتروژنی گوانین (G)، اوراسیل (U)، آدنین (A) و سیتوزین (C) است. ساختار توالی از "."، "(" و ")" است و نشان می‌دهد که آیا پایه‌ها جفت هستند یا خیر. نوع حلقه پیش‌بینی‌شده، مجموعه‌ای از کارکترها است که نوع حلقه احتمالی که هر پایه به آن‌تعلق دارد، اشاره دارد. این کارکترها عبارتند از: چندحلقه (M)، زوج دسته (S)، برآمدگی (B)، حلقه داخلی (I)، حلقه سنجاق‌سری (H)، حلقه خارجی (X) و انتها آویزان (E). هر چند طول توالی کارکترها ۱۰۷ می‌باشد، با این حال به دلیل محدودیت‌های تجربی، به گفته‌ی محققان دانشگاه استنفورد (Stanford University, 2020) تنها اندازه‌گیری ۶۸ پایه اول توالی برای مجموعه‌ای از پنج مقدار هدف (پیش‌بینی) انجام می‌گیرد. این پنج مجموعه مقدار عبارتند از: مقدار واکنش‌پذیری[5] که ساختار ثانویه احتمالی RNA را تعیین می‌کند، مقادیر deg_pH10 وdeg_Mg_pH10 که برای تعیین احتمال ازهم‌پاشیدگی در پایه (پیوند)، به ترتیب، پس از انکوباسیون بدون/با منیزیم در pH بالا (pH10) استفاده می‌شود. و در نهایت، مقادیر deg_50C و deg_Mg_50C، احتمال ازهم‌پاشیدگی در پایه (پیوند)، به ترتیب، پس از انکوباسیون بدون/با منیزیم در دمای بالا (۵۰ درجه سانتی‌گراد) را تعیین می‌کند. آن‌ها هم‌چنین،

[5] reactivity

فیلتری را برای داده‌ها معرفی کردند که کیفیت هر داده را نشان می‌دهد. این فیلتر از معیاری استفاده می‌کند که حداقل مقدار پنج هدف باید بیش‌از ۰.۵- و نسبت سیگنال به نویز بالای ۱ باشد.

اکنون به تشریح روش پیشنهادی در حل مساله پیش‌بینی ازهم‌پاشیدگی mRNA با شبکه‌های عصبی می‌پردازیم. ابتدا داده‌ها باید به‌گونه‌ای نگاشت شوند که شبکه عصبی بتواند آن را پردازش کند. از همین‌رو، ابتدا مجموعه داده را به‌صورت یک ماتریس با کدگذاری One-Hot نگاشت کردیم. یعنی، توالی‌های زوج پایه‌های گوانین، اوراسیل، آدنین و سیتوزین را به اعداد صحیح تبدیل کردیم که در نتیجه چهار ویژگی حاصل شد. هم‌چنین این روش را برای ساختار و حلقه پیش‌بینی‌شده استفاده کردیم که در نتیجه، به ترتیب ۳ و ۷ ویژگی حاصل شد. به عبارت دیگر، به هر یک از کارکترها یک عدد صحیح یکتا اختصاص داده شد. در شکل ۲ مثالی از نحوه این تبدیل برروی یک توالی برای درک بهتر، قابل مشاهده است.

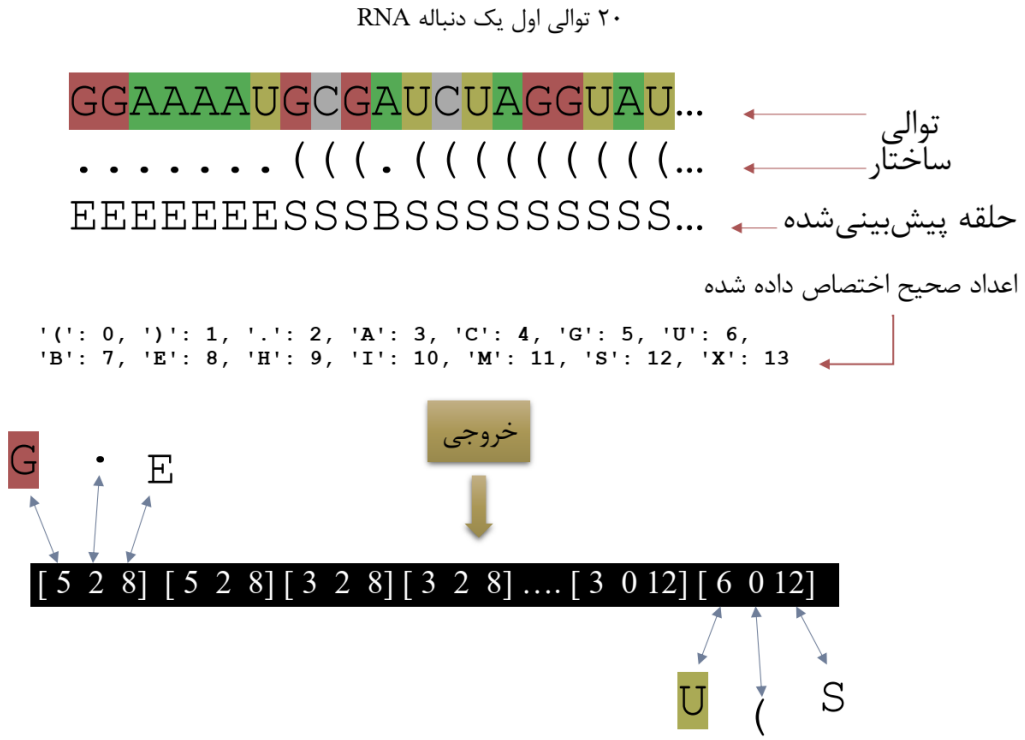

شکل ۲. مثالی از تبدیل‌گذاری One-Hot برروی یک توالی RNA

بعد از تبدیل داده‌ها، آن‌ها را به شبکه از طریق لایه ورودی تغذیه کردیم. پس از لایه ورودی، برای هر چهار معماری LSTM، Bi-LSTM، GRU، Bi-GRU، از سه لایه پنهان استفاده شد. در انتها از یک لایه تمام متصل با ۵ نرون (به تعداد هدف‌ها) استفاده گردید تا یک پیش‌بینی برای هر یک از مقادیر واکنش‌پذیری، deg_pH10، deg_Mg_pH10، deg_50C و deg_Mg_50C داشته باشد. معماری کلی روش پیشنهادی در شکل ۲ قابل مشاهده است.

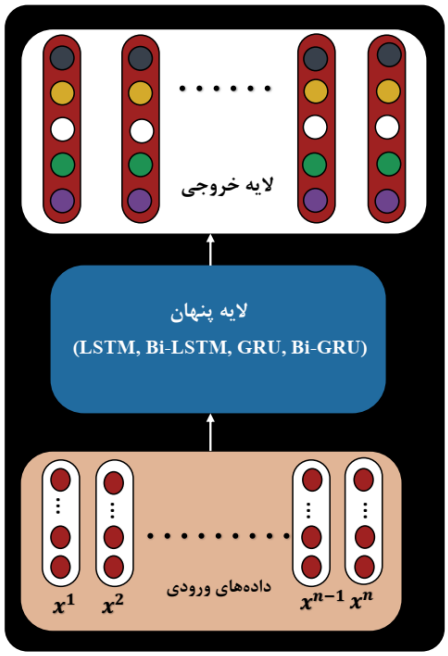

شکل ۳. معماری کلی روش پیشنهادی

پیاده‌سازی تمام مدل‌های این پژوهش با استفاده از زبان پایتون و استفاده از کتاب‌خانه کراس[۶] بر بستر تنسورفلو[۷] صورت گرفته است. کراس یک رابط کابری سطح بالا است که به کاربران اجازه می‌دهد با استفاده از مجموعه‌ای ابزار از پیش‌ساخته، به طراحی مدل‌های یادگیری عمیق بپردازند. هم‌چنین به دلیل محدودیت‌های سخت‌افزاری (GPU)، برای آموزش مدل‌ها از گوگل کولب[۸] استفاده شده است. تمام مدل‌ها در ۵۰ دوره[۹] با اندازه‌های ۳۲ و با بهینه‌ساز آدام[۱۰]، آموزش دیده‌اند.

۳. نتایج و بحث

همان‌طور که پیش‌تر بیان شد، مجموعه داده OpenVaccine RNA دارای ۲۴۰۰ نمونه است. با این حال، ما داده‌ها را از فیلتر سیگنال به نویز عبور داده تا نمونه‌های دارای نویز را حذف کنیم. بنابراین، پس از اعمال فیلتر، ۲۰۹۷ داده آموزشی حاصل شد. از آن‌جایی که ارزیابی کارآیی یک مدل برمحور داده‌هایی است که مدل آن‌ها را تاکنون مشاهده نکرده است، داده‌ها را به دو قسمت داده‌های آموزشی و ارزیابی تقسیم کردیم. براین اساس، تعداد داده‌های آموزشی شامل ۱۸۸۷ و تعداد ۲۱۰ داده برای ارزیابی کارآیی و انتخاب بهترین مدل حاصل شد. ارزیابی مدل‌ها براساس معیار میانگین خطای مجذور میانگین ریشه‌ستونی (MCRMSE[11]) صورت گرفته است. معادله ۱ نحوه محاسبه آن را نشان می‌دهد.

$$MCRMSE = \frac{1}{N_t}\sum_{j=1}^{N_t}\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_{ij}-\hat{y}_{ij})^2} \qquad (۱)$$

[6] https://keras.io
[7] https://www.tensorflow.org
[8] https://colab.research.google.com/notebooks/intro.ipynb
[9] epochs
[10] Adam
[11] mean columnwise root mean squared error

که در این معادله، N_t تعداد ستون‌های هدف (۵) و y_{ij} و $\hat{y}_{ij}$ به ترتیب مقادیر واقعی و پیش‌بینی‌شده است.

در جدول ۱ نتایج حاصل از اجرای چهار مدل یادگیری عمیق، برروی این مجموعه داده براساس معیار MCRMSE در داده‌های آموزشی و ارزیابی، قابل مشاهده است.

جدول ۱. مقایسه کارآیی مدل‌ها

مدل	مجموعه داده آموزشی	مجموعه داده ارزیابی
LSTM	۰.۲۹۹۳	۰.۳۴۳۴
Bi-LSTM	۰.۱۵۶۹	۰.۲۲۰۲
GRU	۰.۳۰۷۶	۰.۳۴۳۷
Bi-GRU	۰.۱۷۶۵	۰.۲۱۹۹

نمودار تابع زیان مدل‌ها در حین آموزش در شکل ۴ قابل مشاهده است.

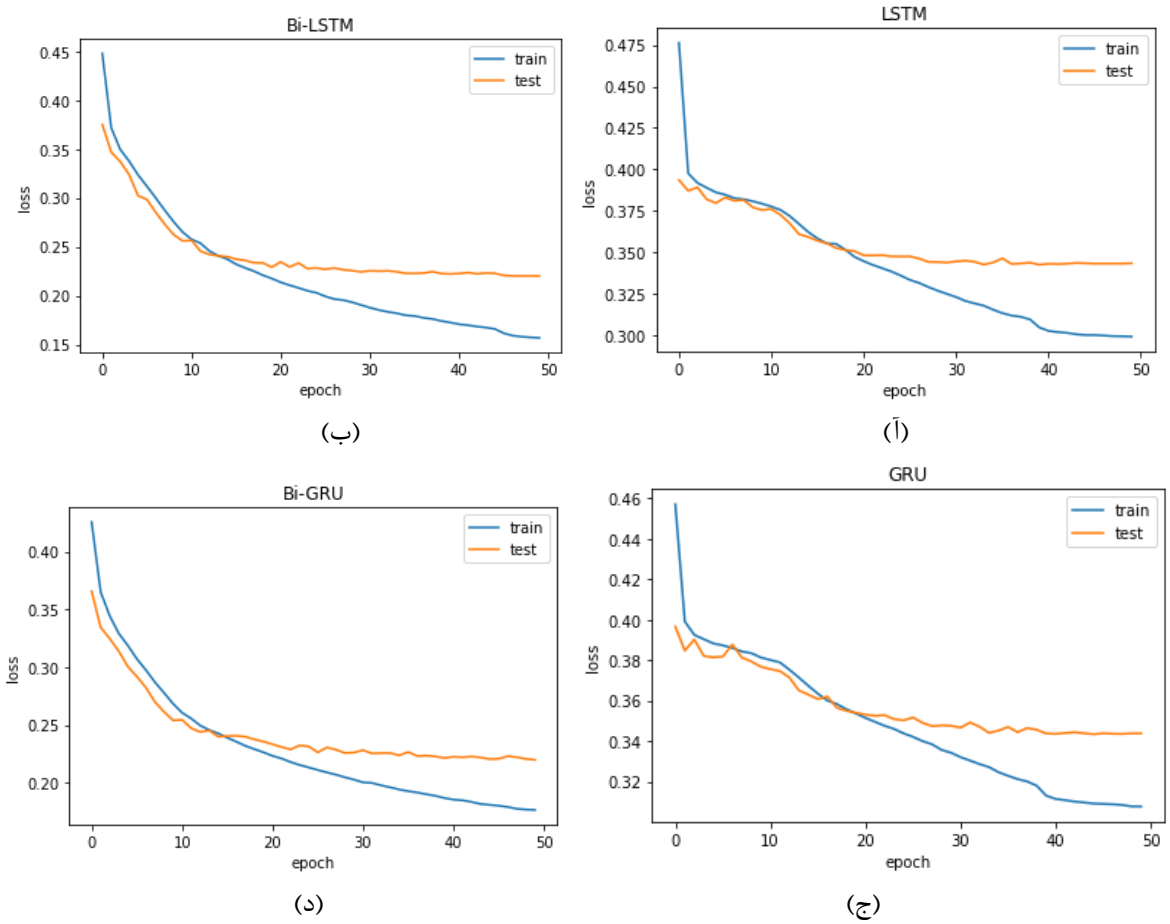

شکل ۴. نمودارهای تابع زیان مدل‌های (آ) LSTM (ب) Bi-LSTM (ج) GRU (د) Bi-GRU

همان‌طور که در جدول ۱ و شکل ۴ مشاهده می‌شود، دو مدل Bi-LSTM و Bi-GRU در مقایسه با دو مدل دیگر کارآیی بهتری هم در مجموعه داده آموزشی و هم در داده‌های ارزیابی در معیار MCRMSE به ترتیب با مقادیر ۰.۲۲۰۲ و ۰.۲۱۹۹ داشته‌اند. با این حال، از آن‌جایی که ارزیابی کارآیی مدل‌ها براساس داده‌هایی است که مدل تاکنون آن‌ها در فرآیند آموزش مشاهده نکرده است، مدل Bi-GRU به دلیل کارآیی بهتر با امتیاز خطای ۰.۲۱۹۹ در مجموعه داده ارزیابی بهترین عملکرد را بدست آورد. علاوه‌بر این، همچنان که در شکل ۴ مشاهده می‌شود، هرچند مدل‌ها نتوانسته‌اند به‌طورکامل همگرایی به‌صورت پیوسته داشته باشند، اما روند تغییرات و مقدار نهایی تابع زیان در مدل Bi-GRU در مقایسه با سایر مدل‌ها بهتر است. از همین‌رو می‌توان نتیجه گرفت که مدلBi-GRU کارآیی بهتری در حل این مساله از خود نشان داده است.

۴. نتیجه‌گیری

جست‌وجو در راستای موثرترین واکسن برای پیروزی بر ویروس کوید-۱۹، محققان را به‌سوی استفاده از واکسن‌های mRNA به دلیل توسعه سریع‌تر و کارآیی بهتر سوق داد. با این حال، توسعه این واکسن‌ها با یک محدودیت جدی همراه است. محققان دریافتند، مولکول‌های RNA تمایل به ازهم‌پاشیدگی خودبه‌خودی دارند و طراحی مولکول‌های mRNA پایدار، بزرگ‌ترین چالش در توسعه این واکسن‌ها می‌باشد. از آن‌جایی که یادگیری عمیق کارآیی بسیار خوبی در زمینه‌های مختلف دارد. در این پژوهش، ما چندین شبکه عصبی بازگشتی را برای پیش‌بینی توالی‌های mRNA که مسبب ازهم‌پاشیدگی mRNA واکسن کوید-۱۹ هستند طراحی کردیم. با مقایسه این چهار مدل، مشاهده گردید که مدل‌های دوطرفه کارآیی بهتری در این خصوص داشتند. هم‌چنین، در این مجموعه داده، مدل Bi-GRU توانست در معیار MCRMSE بهترین امتیاز خطا را با مقدار ۰.۲۱۹۹ به‌دست آورد. در کارهای آینده برای پژوهش می‌توان از شبکه‌های گراف کانولوشنی استفاده و نتایج را با این مدل‌ها مقایسه کرد. وجود مدلی که بتواند پیش‌بینی دقیق‌تری را ممکن سازد، می‌تواند این امید را به‌وجود آورد تا بتوان مولکول‌های mRNA پایدار ساخت. چه‌بسا که در آینده، از این واکسن‌ها نه تنها از آن‌ها برای بیماری‌های عفونی، بلکه برای سرطان به عنوان یک ابزار پیش‌گیرانه استفاده کرد.

References

1- Vazan, Milad. (2021). Deep learning: principles, concepts and approaches.
2- Anand, P. and Stahel, V.P. (2021). The safety of Covid-19 mRNA vaccines: a review. Patient Safety in Surgery, 15(1).
3- Asif Imran, S., Tariqul Islam, Md., Shahnaz, C., Tafhimul Islam, Md., Tawhid Imam, O. and Haque, M. (2020). COVID-19 mRNA Vaccine Degradation Prediction using Regularized LSTM Model. 2020 IEEE International Women in Engineering (WIE) Conference on Electrical and Computer Engineering (WIECON-ECE).
4- Li, Y., Tenchov, R., Smoot, J., Liu, C., Watkins, S. and Zhou, Q. (2021). A Comprehensive Review of the Global Efforts on COVID-19 Vaccine Development. ACS Central Science.
5- Munawar, S., Asif, M., Kabir, B., Pamir, Ullah, A. and Javaid, N. (2021). Electricity Theft Detection in Smart Meters Using a Hybrid Bi-directional GRU Bi-directional LSTM Model. Complex, Intelligent and Software Intensive Systems, pp.297–308.
6- Qaid, T.S., Mazaar, H., Alqahtani, M.S., Raweh, A.A. and Alakwaa, W. (2021). Deep sequence modelling for predicting COVID-19 mRNA vaccine degradation. PeerJ Computer Science, 7, p.e597.
7- Stanford University. (2020). OpenVaccine: COVID-19 mRNA Vaccine Degradation Prediction. [online] Available at: https://www.kaggle.com/c/stanford-covid-vaccine/data.
8- Wayment-Steele, H.K., Kim, D.S., Choe, C.A., Nicol, J.J., Wellington-Oguri, R., Sperberg, R.A.P., Huang, P.-S. and Das, R. (2020). Theoretical basis for stabilizing messenger RNA through secondary structure design.
9- Zhang, C., Maruggi, G., Shan, H. and Li, J. (2019). Advances in mRNA Vaccines for Infectious Diseases. Frontiers in Immunology, 10.
10- Zhou, J., Huang, J.X., Chen, Q., Hu, Q.V., Wang, T. and He, L. (2019). Deep Learning for Aspect-Level Sentiment Classification: Survey, Vision, and Challenges. IEEE Access, 7, pp.78454–78483.